

Fundamentos Matemáticos del Aprendizaje Automático

Nicolas Silva Nash

Departamento de Matemática
Universidad Nacional del Comahue


Director: Dr. Luis Nowak **Codirectora:** Dra. Alejandra Perini

Defensa de Tesina de Licenciatura

- 1 **Aprendizaje automático:** qué significa aprender a partir de ejemplos.
- 2 **Clasificación binaria:** datos, etiquetas, clasificadores, riesgo y clasificador de Bayes.
- 3 **Conceptos del aprendizaje:** generalización, riesgo empírico, consistencia y dilemas.
- 4 **Teoría VC:** ley uniforme, fragmentación y dimensión VC.
- 5 **Límites y panorama actual:** no hay almuerzos gratis y la paradoja moderna.

Aprendizaje automático


Qué significa aprender a partir de ejemplos




A Venn diagram consisting of two concentric circles. The outer circle is light blue and contains the text 'Inteligencia Artificial'. The inner circle is orange and contains the text 'Aprendizaje Automático'. The orange circle is entirely contained within the blue circle, illustrating that Machine Learning is a subset of Artificial Intelligence.


**Inteligencia
Artificial**

**Aprendizaje
Automático**





Pafnuty Chebyshev



Andrey Kolmogorov

¿Qué Entendemos por Aprendizaje?

El aprendizaje es el proceso a través del cual pueden inferirse reglas generales a partir de ejemplos.

¿Qué Entendemos por Aprendizaje?

El aprendizaje es el proceso a través del cual pueden inferirse reglas generales a partir de ejemplos.

Nos interesa entender como una computadora puede resolver ciertos problemas:

¿Qué Entendemos por Aprendizaje?

El aprendizaje es el proceso a través del cual pueden inferirse reglas generales a partir de ejemplos.

Nos interesa entender como una computadora puede resolver ciertos problemas:

- sin conocer las reglas explícitamente de antemano,

¿Qué Entendemos por Aprendizaje?

El aprendizaje es el proceso a través del cual pueden inferirse reglas generales a partir de ejemplos.

Nos interesa entender como una computadora puede resolver ciertos problemas:

- sin conocer las reglas explícitamente de antemano,
- a partir de ejemplos,


¿Qué Entendemos por Aprendizaje?

El aprendizaje es el proceso a través del cual pueden inferirse reglas generales a partir de ejemplos.

Nos interesa entender como una computadora puede resolver ciertos problemas:

- sin conocer las reglas explícitamente de antemano,
- a partir de ejemplos,
- a través de un algoritmo de aprendizaje.


¿Qué significa que una máquina aprenda a clasificar objetos?



Reconocimiento facial mediante landmarks geométricos.

- A partir de **ejemplos**, la máquina construye una regla de decisión.


¿Qué significa que una máquina aprenda a clasificar objetos?



Reconocimiento facial mediante landmarks geométricos.

- A partir de **ejemplos**, la máquina construye una regla de decisión.
- No se programa explícitamente la respuesta: se **infiere** desde los datos.


¿Qué significa que una máquina aprenda a clasificar objetos?



Reconocimiento facial mediante landmarks geométricos.

- A partir de **ejemplos**, la máquina construye una regla de decisión.
- No se programa explícitamente la respuesta: se **infiere** desde los datos.
- El desafío matemático: garantizar que la regla **generalice** a casos nuevos.

¿Qué significa que una máquina aprenda a clasificar objetos?



Reconocimiento facial mediante landmarks geométricos.

- A partir de **ejemplos**, la máquina construye una regla de decisión.
- No se programa explícitamente la respuesta: se **infiere** desde los datos.
- El desafío matemático: garantizar que la regla **generalice** a casos nuevos.

¿Cuándo y por qué funciona?

Clasificación: Planteo del Problema

Consideremos dos espacios de variables: X , llamado espacio de entrada, e Y , el espacio de etiquetas.

Clasificación: Planteo del Problema

Consideremos dos espacios de variables: X , llamado espacio de entrada, e Y , el espacio de etiquetas.

En un problema de clasificación, deseamos poder etiquetar correctamente elementos de X con los valores de Y .



Reconocimiento de distintos tipos de animales

Clasificación: Datos y Clasificador

Asumimos que entre el espacio de entrada y el espacio de etiquetas hay una distribución de probabilidad conjunta $P = P(X, Y)$.

Clasificación: Datos y Clasificador

Asumimos que entre el espacio de entrada y el espacio de etiquetas hay una distribución de probabilidad conjunta $P = P(X, Y)$.

Con el fin de aprender, a un algoritmo se le muestran ejemplos de imágenes y sus respectivas etiquetas $(X_1, Y_1), (X_2, Y_2), \dots, (X_n, Y_n)$, a partir de los cuales este debe encontrar una función $f : X \rightarrow Y$, que comete la menor cantidad de errores posibles.

Clasificación: Datos y Clasificador

Asumimos que entre el espacio de entrada y el espacio de etiquetas hay una distribución de probabilidad conjunta $P = P(X, Y)$.

Con el fin de aprender, a un algoritmo se le muestran ejemplos de imágenes y sus respectivas etiquetas $(X_1, Y_1), (X_2, Y_2), \dots, (X_n, Y_n)$, a partir de los cuales este debe encontrar una función $f : X \rightarrow Y$, que comete la menor cantidad de errores posibles.

A esta función f la llamamos clasificador.

Clasificación: Datos y Clasificador

Asumimos que entre el espacio de entrada y el espacio de etiquetas hay una distribución de probabilidad conjunta $P = P(X, Y)$.

Con el fin de aprender, a un algoritmo se le muestran ejemplos de imágenes y sus respectivas etiquetas $(X_1, Y_1), (X_2, Y_2), \dots, (X_n, Y_n)$, a partir de los cuales este debe encontrar una función $f : X \rightarrow Y$, que comete la menor cantidad de errores posibles.

A esta función f la llamamos clasificador.

A fin de simplificar la teoría, nos centraremos en el más sencillo de los problemas del Machine Learning, el de **clasificación binaria**.

Clasificación: Datos y Clasificador


Asumimos que entre el espacio de entrada y el espacio de etiquetas hay una distribución de probabilidad conjunta $P = P(X, Y)$.

Con el fin de aprender, a un algoritmo se le muestran ejemplos de imágenes y sus respectivas etiquetas $(X_1, Y_1), (X_2, Y_2), \dots, (X_n, Y_n)$, a partir de los cuales este debe encontrar una función $f : X \rightarrow Y$, que comete la menor cantidad de errores posibles.


A esta función f la llamamos clasificador.

A fin de simplificar la teoría, nos centraremos en el más sencillo de los problemas del Machine Learning, el de **clasificación binaria**. En este caso, tendremos dos categorías de etiquetas, por lo que

$$Y = \{-1, +1\}$$



Clasificación de imágenes médicas para diagnóstico de cáncer de mama.



Clasificación de defectos en soldaduras.

Clasificación: Suposiciones básicas

- **No aplicamos restricciones sobre P :** no suponemos una forma paramétrica para la distribución que genera los datos.

Clasificación: Suposiciones básicas

- **No aplicamos restricciones sobre P :** no suponemos una forma paramétrica para la distribución que genera los datos.
- **Etiquetas no determinísticas:** modelamos Y mediante probabilidades condicionales $P(Y = 1 \mid X = x)$.

Clasificación: Suposiciones básicas

- **No aplicamos restricciones sobre P :** no suponemos una forma paramétrica para la distribución que genera los datos.
- **Etiquetas no determinísticas:** modelamos Y mediante probabilidades condicionales $P(Y = 1 \mid X = x)$.
- **Muestreo iid:** los ejemplos se toman de manera independiente e idénticamente distribuida.

Clasificación: Suposiciones básicas

- **No aplicamos restricciones sobre P :** no suponemos una forma paramétrica para la distribución que genera los datos.
- **Etiquetas no determinísticas:** modelamos Y mediante probabilidades condicionales $P(Y = 1 \mid X = x)$.
- **Muestreo iid:** los ejemplos se toman de manera independiente e idénticamente distribuida.
- **Distribución fija:** asumimos que el mecanismo que genera los datos no cambia entre entrenamiento y uso.

Objetivo

Construir $f : X \rightarrow Y$ que generalice a puntos **no vistos**.

Formalizando el Terreno de Juego

Objetivo


Construir $f : X \rightarrow Y$ que generalice a puntos **no vistos**.

Diferencia clave con Estadística clásica

Somos **agnósticos** respecto a P : no asumimos ninguna forma paramétrica.
Conocemos a la distribución P *solo* a través de la muestra finita.

Conceptos del aprendizaje

Generalización, consistencia y dilemas del aprendizaje



¿Qué Significa Equivocarse?: Función de Pérdida

Para medir la efectividad de la función clasificadora, definimos una Función de Pérdida ℓ .

¿Qué Significa Equivocarse?: Función de Pérdida

Para medir la efectividad de la función clasificadora, definimos una Función de Pérdida ℓ .
En el caso binario, la función más sencilla es

Función de pérdida 0-1

$$\ell(X, Y, f(X)) := \begin{cases} 1 & \text{si } f(X) \neq Y \\ 0 & \text{si } f(X) = Y \end{cases}$$

¿Qué Significa Equivocarse?: Función de Pérdida

Para medir la efectividad de la función clasificadora, definimos una Función de Pérdida ℓ .
En el caso binario, la función más sencilla es

Función de pérdida 0-1

$$\ell(X, Y, f(X)) := \begin{cases} 1 & \text{si } f(X) \neq Y \\ 0 & \text{si } f(X) = Y \end{cases}$$

Por convención, una pérdida igual a 0 implica una clasificación perfecta y valores mayores implican peor clasificación.

¿Qué Significa Equivocarse?: Función de Riesgo

Mientras que la función de pérdida mide el error del clasificador en un punto individual $x \in X$, llamamos riesgo, R , del clasificador a la pérdida esperada sobre todos los datos generados por la distribución de probabilidad P

¿Qué Significa Equivocarse?: Función de Riesgo

Mientras que la función de pérdida mide el error del clasificador en un punto individual $x \in X$, llamamos riesgo, R , del clasificador a la pérdida esperada sobre todos los datos generados por la distribución de probabilidad P

Riesgo

$$\mathcal{R}(f) := \mathbb{E}_P[\ell(X, Y, f(X))]$$

¿Qué Significa Equivocarse?: Función de Riesgo

Mientras que la función de pérdida mide el error del clasificador en un punto individual $x \in X$, llamamos riesgo, R , del clasificador a la pérdida esperada sobre todos los datos generados por la distribución de probabilidad P

Riesgo

$$\mathcal{R}(f) := \mathbb{E}_P[\ell(X, Y, f(X))]$$

El mejor clasificador posible minimiza $\mathcal{R}$.

¿Qué Significa Equivocarse?: Función de Riesgo

Mientras que la función de pérdida mide el error del clasificador en un punto individual $x \in X$, llamamos riesgo, R , del clasificador a la pérdida esperada sobre todos los datos generados por la distribución de probabilidad P

Riesgo

$$\mathcal{R}(f) := \mathbb{E}_P[\ell(X, Y, f(X))]$$

El mejor clasificador posible minimiza $\mathcal{R}$.

Es decir, el aprendizaje implica un desafío de optimización en dónde deseamos hallar el mínimo de la función de riesgo.

Clasificador de Bayes:

$$f_{\text{Bayes}}(x) := \begin{cases} +1 & \text{si } P(Y = 1 \mid X = x) \geq \frac{1}{2} \\ -1 & \text{en otro caso} \end{cases}$$

Clasificador de Bayes:

$$f_{\text{Bayes}}(x) := \begin{cases} +1 & \text{si } P(Y = 1 \mid X = x) \geq \frac{1}{2} \\ -1 & \text{en otro caso} \end{cases}$$

- Minimiza $\mathcal{R}(f)$ sobre **todas** las funciones medibles.

Clasificador de Bayes:

$$f_{\text{Bayes}}(x) := \begin{cases} +1 & \text{si } P(Y = 1 \mid X = x) \geq \frac{1}{2} \\ -1 & \text{en otro caso} \end{cases}$$

- Minimiza $\mathcal{R}(f)$ sobre **todas** las funciones medibles.
- Asigna siempre la etiqueta más probable dado x .

Clasificador de Bayes:

$$f_{\text{Bayes}}(x) := \begin{cases} +1 & \text{si } P(Y = 1 \mid X = x) \geq \frac{1}{2} \\ -1 & \text{en otro caso} \end{cases}$$

- Minimiza $\mathcal{R}(f)$ sobre **todas** las funciones medibles.
- Asigna siempre la etiqueta más probable dado x .
- Es el **techo teórico** de cualquier clasificador.

Clasificador de Bayes:

$$f_{\text{Bayes}}(x) := \begin{cases} +1 & \text{si } P(Y = 1 \mid X = x) \geq \frac{1}{2} \\ -1 & \text{en otro caso} \end{cases}$$

- Minimiza $\mathcal{R}(f)$ sobre **todas** las funciones medibles.
- Asigna siempre la etiqueta más probable dado x .
- Es el **techo teórico** de cualquier clasificador.

¿Por qué es inalcanzable?

Requiere conocer $P(X, Y)$, **que es exactamente lo que desconocemos.**

Definición del problema de clasificación binaria

Si el clasificador de Bayes es incomputable en la práctica, ¿Qué utilidad tiene definirlo?

Definición del problema de clasificación binaria

Si el clasificador de Bayes es incomputable en la práctica, ¿Qué utilidad tiene definirlo?

Lo hacemos porque nos permite definir el problema que estamos tratando.

Definición del problema de clasificación binaria

Si el clasificador de Bayes es incomputable en la práctica, ¿Qué utilidad tiene definirlo?

Lo hacemos porque nos permite definir el problema que estamos tratando.

Definición

Dado un conjunto de datos de entrenamiento $\{(X_1, Y_1), \dots, (X_n, Y_m)\}$ obtenidos iid de una distribución P , y dada una función de pérdida ℓ , deseamos construir una función clasificadora $f : X \rightarrow Y$ cuyo riesgo $\mathcal{R}(f)$ sea lo más cercano posible al riesgo de f_{Bayes} . Llamamos a este problema **clasificación binaria**.

Definición del problema de clasificación binaria

Si el clasificador de Bayes es incomputable en la práctica, ¿Qué utilidad tiene definirlo?

Lo hacemos porque nos permite definir el problema que estamos tratando.

Definición

Dado un conjunto de datos de entrenamiento $\{(X_1, Y_1), \dots, (X_n, Y_m)\}$ obtenidos iid de una distribución P , y dada una función de pérdida ℓ , deseamos construir una función clasificadora $f : X \rightarrow Y$ cuyo riesgo $\mathcal{R}(f)$ sea lo más cercano posible al riesgo de f_{Bayes} . Llamamos a este problema **clasificación binaria**.

Pero... ¿Cómo construimos esta función clasificadora?

Definición

Llamamos **algoritmo de aprendizaje** a todo procedimiento matemático que, dado un conjunto de datos de entrenamiento (X_i, Y_i) , devuelve una función clasificadora f sobre el espacio de entrada X y el espacio de etiquetas Y del que provienen los datos.

Definición

Llamamos **algoritmo de aprendizaje** a todo procedimiento matemático que, dado un conjunto de datos de entrenamiento (X_i, Y_i) , devuelve una función clasificadora f sobre el espacio de entrada X y el espacio de etiquetas Y del que provienen los datos.

El algoritmo define la forma de la función clasificadora. En general, a través de este determinamos al espacio funcional $\mathcal{F}$ de donde extraemos los distintos clasificadores del proceso de aprendizaje.

Ejemplo: El perceptrón de Rosenblatt


Dado un conjunto de entrenamiento $S = \{(\mathbf{x}_i, y_i)\}_{i=1}^n \subset \mathbb{R}^d \times \{0, 1\}$, el Perceptrón se define como un clasificador binario $h : \mathbb{R}^d \rightarrow \{-1, 1\}$ mediante la siguiente función:



$$h_{\mathbf{w}}(\mathbf{x}) = \text{sgn}(\mathbf{w}^T \mathbf{x} > 0)$$




Donde $\mathbf{w} \in \mathbb{R}^d$ es el vector de pesos y $\text{sgn}(\cdot)$ denota la función Signum. El aprendizaje de los parámetros se realiza a través de una regla de actualización iterativa. Para cada muestra $(\mathbf{x}_i, y_i)$, la actualización se define como:





$$\mathbf{w}^{(t+1)} \leftarrow \mathbf{w}^{(t)} + \eta(y_i - \hat{y}_i)\mathbf{x}_i$$

donde $\hat{y}_i = h_{\mathbf{w}^{(t)}}(\mathbf{x}_i)$ es la predicción actual y $\eta \in (0, 1]$ es llamada la tasa de aprendizaje.









Consistencia

Sea $(X_i, Y_i)_{i \in \mathbb{N}}$ una sucesión infinita de puntos de entrenamiento que han sido tomados iid de una distribución P . Sea ℓ una función de pérdida. Por cada $n \in \mathbb{N}$, sea f_n un clasificador construido por algún algoritmo de aprendizaje usando los primeros n puntos de entrenamiento. Sea $\mathcal{F}$ el espacio funcional de todos los posibles clasificadores según el mecanismo de construcción del algoritmo.

Consistencia

Sea $(X_i, Y_i)_{i \in \mathbb{N}}$ una sucesión infinita de puntos de entrenamiento que han sido tomados iid de una distribución P . Sea ℓ una función de pérdida. Por cada $n \in \mathbb{N}$, sea f_n un clasificador construido por algún algoritmo de aprendizaje usando los primeros n puntos de entrenamiento. Sea $\mathcal{F}$ el espacio funcional de todos los posibles clasificadores según el mecanismo de construcción del algoritmo. Entonces

- 1 El algoritmo de aprendizaje se dice consistente con respecto a $\mathcal{F}$ y a P si el riesgo $\mathcal{R}(f_n)$ converge en probabilidad al riesgo $\mathcal{R}(f_{\mathcal{F}})$ del mejor clasificador en $\mathcal{F}$. Esto es, que para todo $\varepsilon > 0$:

$$P(\mathcal{R}(f_n) - \mathcal{R}(f_{\mathcal{F}}) > \varepsilon) \rightarrow 0 \quad \text{cuando} \quad n \rightarrow \infty$$

Consistencia

Sea $(X_i, Y_i)_{i \in \mathbb{N}}$ una sucesión infinita de puntos de entrenamiento que han sido tomados iid de una distribución P . Sea ℓ una función de pérdida. Por cada $n \in \mathbb{N}$, sea f_n un clasificador construido por algún algoritmo de aprendizaje usando los primeros n puntos de entrenamiento. Sea $\mathcal{F}$ el espacio funcional de todos los posibles clasificadores según el mecanismo de construcción del algoritmo. Entonces

- 1 El algoritmo de aprendizaje se dice consistente con respecto a $\mathcal{F}$ y a P si el riesgo $\mathcal{R}(f_n)$ converge en probabilidad al riesgo $\mathcal{R}(f_{\mathcal{F}})$ del mejor clasificador en $\mathcal{F}$. Esto es, que para todo $\varepsilon > 0$:

$$P(\mathcal{R}(f_n) - \mathcal{R}(f_{\mathcal{F}}) > \varepsilon) \rightarrow 0 \quad \text{cuando} \quad n \rightarrow \infty$$

- 2 El algoritmo de aprendizaje se dice Bayes-consistente con respecto a P si el riesgo $\mathcal{R}(f_n)$ converge en probabilidad al riesgo $\mathcal{R}(f_{\text{Bayes}})$ del clasificador bayesiano. Esto es, para todo $\varepsilon > 0$

$$P(\mathcal{R}(f_n) - \mathcal{R}(f_{\text{Bayes}}) > \varepsilon) \rightarrow 0 \quad \text{cuando} \quad n \rightarrow \infty$$

Hay muchas cosas que no podemos calcular

No somos capaces de hallar al clasificador de Bayes.

Hay muchas cosas que no podemos calcular

No somos capaces de hallar al clasificador de Bayes.

En general, no podemos hallar explícitamente al mejor clasificador de un espacio funcional.

Hay muchas cosas que no podemos calcular

No somos capaces de hallar al clasificador de Bayes.

En general, no podemos hallar explícitamente al mejor clasificador de un espacio funcional.

Ni siquiera podemos calcular el riesgo de un clasificador conocido.

...

¿Qué podemos hacer?

Hay muchas cosas que no podemos calcular

No somos capaces de hallar al clasificador de Bayes.

En general, no podemos hallar explícitamente al mejor clasificador de un espacio funcional.

Ni siquiera podemos calcular el riesgo de un clasificador conocido.

...

¿Qué podemos hacer?

Podemos “contar” el número de errores del clasificador sobre los datos de entrenamiento.

Definición

Sea $(X_i, Y_i)_{i=1}^n$ un conjunto de datos de entrenamiento, donde cada (X_i, Y_i) es tomado iid de una distribución de probabilidad $P(X, Y)$. Sea ℓ una función de pérdida. Sea f_n un clasificador binario construido a partir de ejemplos, luego de ser presentado con los primeros n datos de entrenamiento. Entonces el **riesgo empírico** del clasificador f es la pérdida promedio sobre los datos de entrenamiento, es decir

$$R_{emp}(f) := \frac{1}{n} \sum_{i=1}^n \ell(X_i, Y_i, f(X_i))$$

Desearíamos que el riesgo empírico se halle “cerca” del real, porque podríamos inferir la calidad de nuestro clasificador para toda la distribución y no solo en los datos de entrenamiento.

Desearíamos que el riesgo empírico se halle “cerca” del real, porque podríamos inferir la calidad de nuestro clasificador para toda la distribución y no solo en los datos de entrenamiento.

Llamamos a esta idea **generalización**.

Desearíamos que el riesgo empírico se halle “cerca” del real, porque podríamos inferir la calidad de nuestro clasificador para toda la distribución y no solo en los datos de entrenamiento.


Llamamos a esta idea **generalización**.

Generalización

Desearíamos que

$$\mathcal{R}_{\text{emp}}(f) \approx \mathcal{R}(f)$$

Generalización




El Dilema de la Complejidad

$$\begin{aligned} & \underbrace{\mathcal{R}(f_n) - \mathcal{R}(f_{\text{Bayes}})}_{\text{lo que queremos reducir}} \\ = & \underbrace{\mathcal{R}(f_n) - \mathcal{R}(f_{\mathcal{F}})}_{\text{error de estimación}} + \underbrace{\mathcal{R}(f_{\mathcal{F}}) - \mathcal{R}(f_{\text{Bayes}})}_{\text{error de aproximación}} \end{aligned}$$

El Dilema de la Complejidad


$$\begin{aligned} & \underbrace{\mathcal{R}(f_n) - \mathcal{R}(f_{\text{Bayes}})}_{\text{lo que queremos reducir}} \\ = & \underbrace{\mathcal{R}(f_n) - \mathcal{R}(f_{\mathcal{F}})}_{\text{error de estimación}} + \underbrace{\mathcal{R}(f_{\mathcal{F}}) - \mathcal{R}(f_{\text{Bayes}})}_{\text{error de aproximación}} \end{aligned}$$



El Dilema Sesgo-Varianza

- Si $\mathcal{F}$ es **poco compleja**, minimizamos el **error de estimación** (alto sesgo).
- Si $\mathcal{F}$ es **muy compleja**, minimizamos el **error de aproximación** (alta varianza).
- La generalización mejora en un punto intermedio: **ni demasiado simple ni demasiado complejo**.


$$\underbrace{\mathcal{R}(f_n) - \mathcal{R}(f_{\mathcal{F}})}_{\text{error de estimación}} + \underbrace{\mathcal{R}(f_{\mathcal{F}}) - \mathcal{R}(f_{\text{Bayes}})}_{\text{error de aproximación}}$$



El Dilema Sesgo-Varianza


- Si $\mathcal{F}$ es **poco compleja**, minimizamos el **error de estimación** (alto sesgo).
- Si $\mathcal{F}$ es **muy compleja**, minimizamos el **error de aproximación** (alta varianza).
- La generalización mejora en un punto intermedio: **ni demasiado simple ni demasiado compleja**.

$$\underbrace{\mathcal{R}(f_n) - \mathcal{R}(f_{\mathcal{F}})}_{\text{error de estimaci3n}} + \underbrace{\mathcal{R}(f_{\mathcal{F}}) - \mathcal{R}(f_{\text{Bayes}})}_{\text{error de aproximaci3n}}$$




El error de aproximación disminuye con la complejidad, mientras que el error de estimación aumenta a partir de un punto *óptimo*.


Subajuste y sobreajuste



Subajuste y sobreajuste




Subajuste




Sobreajuste


Subajuste y sobreajuste



Subajuste



Sobreajuste



Balanceado

"[Funes] había aprendido sin esfuerzo el inglés, el francés, el portugués, el latín. Sospecho, sin embargo, que no era muy capaz de pensar. Pensar es olvidar diferencias, es generalizar, abstraer. En el abarrotado mundo de Funes no había sino detalles, casi inmediatos."

— Jorge Luis Borges,
Funes el memorioso

Teoría VC

Ley uniforme, fragmentación y dimensión VC

La Ley de los Grandes Números

En su forma más simple, la ley de los grandes números establece que, bajo condiciones suaves, la media de variables aleatorias ξ_i que han sido extraídas de manera *iid* a partir de una distribución de probabilidad P , converge a la media de la distribución subyacente cuando el tamaño de la muestra tiende a infinito:

La Ley de los Grandes Números

En su forma más simple, la ley de los grandes números establece que, bajo condiciones suaves, la media de variables aleatorias ξ_i que han sido extraídas de manera *iid* a partir de una distribución de probabilidad P , converge a la media de la distribución subyacente cuando el tamaño de la muestra tiende a infinito:

$$\frac{1}{n} \sum_{i=1}^n \xi_i \rightarrow \mathbb{E}(\xi) \quad \text{cuando } n \rightarrow \infty.$$

La Ley de los Grandes Números

En su forma más simple, la ley de los grandes números establece que, bajo condiciones suaves, la media de variables aleatorias ξ_i que han sido extraídas de manera *iid* a partir de una distribución de probabilidad P , converge a la media de la distribución subyacente cuando el tamaño de la muestra tiende a infinito:

$$\frac{1}{n} \sum_{i=1}^n \xi_i \rightarrow \mathbb{E}(\xi) \quad \text{cuando } n \rightarrow \infty.$$

Tomando $\xi_i = \ell(X_i, Y_i, f(X_i))$, **para una función fija f** ,

La Ley de los Grandes Números

En su forma más simple, la ley de los grandes números establece que, bajo condiciones suaves, la media de variables aleatorias ξ_i que han sido extraídas de manera *iid* a partir de una distribución de probabilidad P , converge a la media de la distribución subyacente cuando el tamaño de la muestra tiende a infinito:

$$\frac{1}{n} \sum_{i=1}^n \xi_i \rightarrow \mathbb{E}(\xi) \quad \text{cuando } n \rightarrow \infty.$$

Tomando $\xi_i = \ell(X_i, Y_i, f(X_i))$, **para una función fija f** , tenemos

$$\frac{1}{n} \sum_{i=1}^n \ell(X_i, Y_i, f(X_i)) \rightarrow \mathbb{E}(\ell(X, Y, f(X))) \quad \text{cuando } n \rightarrow \infty.$$

La Ley de los Grandes Números

En su forma más simple, la ley de los grandes números establece que, bajo condiciones suaves, la media de variables aleatorias ξ_i que han sido extraídas de manera *iid* a partir de una distribución de probabilidad P , converge a la media de la distribución subyacente cuando el tamaño de la muestra tiende a infinito:

$$\frac{1}{n} \sum_{i=1}^n \xi_i \rightarrow \mathbb{E}(\xi) \quad \text{cuando } n \rightarrow \infty.$$

Tomando $\xi_i = \ell(X_i, Y_i, f(X_i))$, **para una función fija f** , tenemos

$$\frac{1}{n} \sum_{i=1}^n \ell(X_i, Y_i, f(X_i)) \rightarrow \mathbb{E}(\ell(X, Y, f(X))) \quad \text{cuando } n \rightarrow \infty.$$

O lo que es lo mismo:

$$\mathcal{R}_{\text{emp}}^n(f) \rightarrow \mathcal{R}(f) \quad \text{cuando } n \rightarrow \infty.$$

La Cota de Chernoff-Hoeffding nos permite obtener una cota de probabilidad para la diferencia entre el riesgo empírico y el riesgo real de una función fija f . En particular, si $\xi_1, \dots, \xi_n$ son variables aleatorias independientes acotadas en el intervalo $[0, 1]$ con media $\mathbb{E}(\xi)$, entonces para cualquier $\varepsilon > 0$ se cumple que

$$P\left(\left|\frac{1}{n}\sum_{i=1}^n \xi_i - \mathbb{E}(\xi)\right| \geq \varepsilon\right) \leq 2 \exp(-2n\varepsilon^2).$$

La Cota de Chernoff-Hoeffding nos permite obtener una cota de probabilidad para la diferencia entre el riesgo empírico y el riesgo real de una función fija f . En particular, si $\xi_1, \dots, \xi_n$ son variables aleatorias independientes acotadas en el intervalo $[0, 1]$ con media $\mathbb{E}(\xi)$, entonces para cualquier $\varepsilon > 0$ se cumple que

$$P\left(\left|\frac{1}{n} \sum_{i=1}^n \xi_i - \mathbb{E}(\xi)\right| \geq \varepsilon\right) \leq 2 \exp(-2n\varepsilon^2).$$

Es decir, para una función fija f :

Cota de Chernoff-Hoeffding

$$P(|\mathcal{R}_{\text{emp}}(f) - \mathcal{R}(f)| \geq \varepsilon) \leq 2 \exp(-2n\varepsilon^2).$$

Un algoritmo de aprendizaje arroja una función distinta por cada ejemplo de entrenamiento que ve. Esto implica que, a medida que el número de elementos n en el conjunto de entrenamiento crece, la función que se define cambia.

Un algoritmo de aprendizaje arroja una función distinta por cada ejemplo de entrenamiento que ve. Esto implica que, a medida que el número de elementos n en el conjunto de entrenamiento crece, la función que se define cambia.

Nos gustaría poder aplicar la Ley de los Grandes Números a esta función, pero no podemos porque no es fija.

Un algoritmo de aprendizaje arroja una función distinta por cada ejemplo de entrenamiento que ve. Esto implica que, a medida que el número de elementos n en el conjunto de entrenamiento crece, la función que se define cambia.

Nos gustaría poder aplicar la Ley de los Grandes Números a esta función, pero no podemos porque no es fija.

Análogamente, la cota de Chernoff-Hoeffding no se puede aplicar directamente a nuestro caso porque cada punto nuevo cambia la función que estamos tratando.

Un algoritmo de aprendizaje arroja una función distinta por cada ejemplo de entrenamiento que ve. Esto implica que, a medida que el número de elementos n en el conjunto de entrenamiento crece, la función que se define cambia.

Nos gustaría poder aplicar la Ley de los Grandes Números a esta función, pero no podemos porque no es fija.

Análogamente, la cota de Chernoff-Hoeffding no se puede aplicar directamente a nuestro caso porque cada punto nuevo cambia la función que estamos tratando.

Nuestro objetivo será entonces encontrar condiciones bajo las cuales podamos aplicar esta cota a funciones que no son fijas, sino que cambian con cada nuevo ejemplo de entrenamiento.

Un algoritmo de aprendizaje arroja una función distinta por cada ejemplo de entrenamiento que ve. Esto implica que, a medida que el número de elementos n en el conjunto de entrenamiento crece, la función que se define cambia.

Nos gustaría poder aplicar la Ley de los Grandes Números a esta función, pero no podemos porque no es fija.

Análogamente, la cota de Chernoff-Hoeffding no se puede aplicar directamente a nuestro caso porque cada punto nuevo cambia la función que estamos tratando.

Nuestro objetivo será entonces encontrar condiciones bajo las cuales podamos aplicar esta cota a funciones que no son fijas, sino que cambian con cada nuevo ejemplo de entrenamiento.

Esto implica una generalización de la Ley de los Grandes Números, a la que llamamos la **ley uniforme de los grandes números**.

Hacia una Ley Uniforme de los Grandes Números

Sea $\mathcal{F}$ un espacio funcional de clasificadores. Para poder dar certezas no para una, sino para cualquier función del espacio, debemos de ser capaces de acotar la diferencia entre el riesgo empírico y el riesgo real para todas las funciones del espacio. Queremos entonces hallar condiciones bajo las cuales se cumple que, para todo $\varepsilon > 0$,

$$\sup_{f \in \mathcal{F}} |\mathcal{R}(f) - \mathcal{R}_{\text{emp}}(f)| \leq \varepsilon.$$

Hacia una Ley Uniforme de los Grandes Números

Sea $\mathcal{F}$ un espacio funcional de clasificadores. Para poder dar certezas no para una, sino para cualquier función del espacio, debemos de ser capaces de acotar la diferencia entre el riesgo empírico y el riesgo real para todas las funciones del espacio. Queremos entonces hallar condiciones bajo las cuales se cumple que, para todo $\varepsilon > 0$,

$$\sup_{f \in \mathcal{F}} |\mathcal{R}(f) - \mathcal{R}_{\text{emp}}(f)| \leq \varepsilon.$$

Es claro que

$$P(|R(f_n) - \mathcal{R}_{\text{emp}}(f_n)| \geq \varepsilon) \leq P\left(\sup_{f \in \mathcal{F}} |\mathcal{R}(f) - \mathcal{R}_{\text{emp}}(f)| \geq \varepsilon\right).$$

Hacia una Ley Uniforme de los Grandes Números

Sea $\mathcal{F}$ un espacio funcional de clasificadores. Para poder dar certezas no para una, sino para cualquier función del espacio, debemos de ser capaces de acotar la diferencia entre el riesgo empírico y el riesgo real para todas las funciones del espacio. Queremos entonces hallar condiciones bajo las cuales se cumple que, para todo $\varepsilon > 0$,

$$\sup_{f \in \mathcal{F}} |\mathcal{R}(f) - \mathcal{R}_{\text{emp}}(f)| \leq \varepsilon.$$

Es claro que

$$P(|\mathcal{R}(f_n) - \mathcal{R}_{\text{emp}}(f_n)| \geq \varepsilon) \leq P\left(\sup_{f \in \mathcal{F}} |\mathcal{R}(f) - \mathcal{R}_{\text{emp}}(f)| \geq \varepsilon\right).$$

Decimos que la ley de los grandes números se cumple de manera uniforme sobre una clase de funciones $\mathcal{F}$ si, para todo $\varepsilon > 0$,

$$P\left(\sup_{f \in \mathcal{F}} |\mathcal{R}(f) - \mathcal{R}_{\text{emp}}(f)| \geq \varepsilon\right) \rightarrow 0 \quad \text{cuando } n \rightarrow \infty.$$

Definición

Sea $\mathcal{F}$ un espacio funcional, R_{emp} el riesgo empírico asociado a una función de pérdida ℓ . Supongamos que tenemos una muestra de tamaño n . Definimos el clasificador f_n como la función:

$$f_n := \arg \min_{f \in \mathcal{F}} \mathcal{R}_{emp}(f).$$

Definición

Sea $\mathcal{F}$ un espacio funcional, R_{emp} el riesgo empírico asociado a una función de pérdida ℓ . Supongamos que tenemos una muestra de tamaño n . Definimos el clasificador f_n como la función:

$$f_n := \arg \min_{f \in \mathcal{F}} \mathcal{R}_{emp}(f).$$

Definición

Sea $\mathcal{F}$ un espacio funcional, R_{emp} el riesgo empírico asociado a una función de pérdida ℓ . Supongamos que tenemos una muestra de tamaño n . Definimos el clasificador f_n como la función:

$$f_n := \arg \min_{f \in \mathcal{F}} \mathcal{R}_{emp}(f).$$

El proceso de encontrar esta función se conoce como **minimización del riesgo empírico** (MRE).

Definición

Sea $\mathcal{F}$ un espacio funcional, R_{emp} el riesgo empírico asociado a una función de pérdida ℓ . Supongamos que tenemos una muestra de tamaño n . Definimos el clasificador f_n como la función:

$$f_n := \arg \min_{f \in \mathcal{F}} \mathcal{R}_{emp}(f).$$

El proceso de encontrar esta función se conoce como **minimización del riesgo empírico** (MRE).

Notemos que

$$R_{emp}(f_n) - R_{emp}(f_{\mathcal{F}}) \leq 0, \quad R(f_n) - R(f_{\mathcal{F}}) \geq 0$$

por definición de f_n y $f_{\mathcal{F}}$ respectivamente.

Notemos que

$$R_{emp}(f_n) - R_{emp}(f_{\mathcal{F}}) \leq 0, \quad R(f_n) - R(f_{\mathcal{F}}) \geq 0$$

por definición de f_n y $f_{\mathcal{F}}$ respectivamente. Luego

$$|R(f_n) - R(f_{\mathcal{F}})| = R(f_n) - R(f_{\mathcal{F}})$$

Notemos que

$$R_{\text{emp}}(f_n) - R_{\text{emp}}(f_{\mathcal{F}}) \leq 0, \quad R(f_n) - R(f_{\mathcal{F}}) \geq 0$$

por definición de f_n y $f_{\mathcal{F}}$ respectivamente. Luego

$$|R(f_n) - R(f_{\mathcal{F}})| = R(f_n) - R(f_{\mathcal{F}})$$

Sumando y restando cantidades idénticas:

$$= R(f_n) + [\mathcal{R}_{\text{emp}}(f_n) - \mathcal{R}_{\text{emp}}(f_n)] + [\mathcal{R}_{\text{emp}}(f_{\mathcal{F}}) - \mathcal{R}_{\text{emp}}(f_{\mathcal{F}})] - R(f_{\mathcal{F}})$$

Notemos que

$$R_{\text{emp}}(f_n) - R_{\text{emp}}(f_{\mathcal{F}}) \leq 0, \quad R(f_n) - R(f_{\mathcal{F}}) \geq 0$$

por definición de f_n y $f_{\mathcal{F}}$ respectivamente. Luego

$$|R(f_n) - R(f_{\mathcal{F}})| = R(f_n) - R(f_{\mathcal{F}})$$

Sumando y restando cantidades idénticas:

$$= R(f_n) + [\mathcal{R}_{\text{emp}}(f_n) - \mathcal{R}_{\text{emp}}(f_n)] + [\mathcal{R}_{\text{emp}}(f_{\mathcal{F}}) - \mathcal{R}_{\text{emp}}(f_{\mathcal{F}})] - R(f_{\mathcal{F}})$$

$$\leq R(f_n) - \mathcal{R}_{\text{emp}}(f_n) + \mathcal{R}_{\text{emp}}(f_{\mathcal{F}}) - R(f_{\mathcal{F}})$$

Notemos que

$$R_{\text{emp}}(f_n) - R_{\text{emp}}(f_{\mathcal{F}}) \leq 0, \quad R(f_n) - R(f_{\mathcal{F}}) \geq 0$$

por definición de f_n y $f_{\mathcal{F}}$ respectivamente. Luego

$$|R(f_n) - R(f_{\mathcal{F}})| = R(f_n) - R(f_{\mathcal{F}})$$

Sumando y restando cantidades idénticas:

$$= R(f_n) + [\mathcal{R}_{\text{emp}}(f_n) - \mathcal{R}_{\text{emp}}(f_n)] + [\mathcal{R}_{\text{emp}}(f_{\mathcal{F}}) - \mathcal{R}_{\text{emp}}(f_{\mathcal{F}})] - R(f_{\mathcal{F}})$$

$$\leq R(f_n) - \mathcal{R}_{\text{emp}}(f_n) + \mathcal{R}_{\text{emp}}(f_{\mathcal{F}}) - R(f_{\mathcal{F}})$$

$$\leq 2 \sup_{f \in \mathcal{F}} |\mathcal{R}(f) - \mathcal{R}_{\text{emp}}(f)|.$$

Acotando al tomar el supremo de todas las funciones en el espacio $\mathcal{F}$.

Notemos que

$$R_{\text{emp}}(f_n) - R_{\text{emp}}(f_{\mathcal{F}}) \leq 0, \quad R(f_n) - R(f_{\mathcal{F}}) \geq 0$$

por definición de f_n y $f_{\mathcal{F}}$ respectivamente. Luego

$$|R(f_n) - R(f_{\mathcal{F}})| = R(f_n) - R(f_{\mathcal{F}})$$

Sumando y restando cantidades idénticas:

$$= R(f_n) + [\mathcal{R}_{\text{emp}}(f_n) - \mathcal{R}_{\text{emp}}(f_n)] + [\mathcal{R}_{\text{emp}}(f_{\mathcal{F}}) - \mathcal{R}_{\text{emp}}(f_{\mathcal{F}})] - R(f_{\mathcal{F}})$$

$$\leq R(f_n) - \mathcal{R}_{\text{emp}}(f_n) + \mathcal{R}_{\text{emp}}(f_{\mathcal{F}}) - R(f_{\mathcal{F}})$$

$$\leq 2 \sup_{f \in \mathcal{F}} |\mathcal{R}(f) - \mathcal{R}_{\text{emp}}(f)|.$$

Acotando al tomar el supremo de todas las funciones en el espacio $\mathcal{F}$. De esto podemos concluir:

$$P(|R(f_n) - R(f_{\mathcal{F}})| \geq \varepsilon) \leq P\left(\sup_{f \in \mathcal{F}} |\mathcal{R}(f) - \mathcal{R}_{\text{emp}}(f)| \geq \varepsilon/2\right).$$

La convergencia uniforme sobre $\mathcal{F}$ es una condición suficiente para la consistencia de la MRE sobre $\mathcal{F}$.

La convergencia uniforme sobre $\mathcal{F}$ es una condición suficiente para la consistencia de la MRE sobre $\mathcal{F}$.

En este trabajo demostramos que el recíproco también es cierto.

La convergencia uniforme sobre $\mathcal{F}$ es una condición suficiente para la consistencia de la MRE sobre $\mathcal{F}$.

En este trabajo demostramos que el recíproco también es cierto.

Teorema (Vapnik y Chervonenkis, 1971)

La convergencia uniforme

$$P\left(\sup_{f \in \mathcal{F}} |\mathcal{R}(f) - \mathcal{R}_{\text{emp}}(f)| > \varepsilon\right) \rightarrow 0 \quad \text{cuando } n \rightarrow \infty,$$

para todo $\varepsilon > 0$, es una condición necesaria y suficiente para la consistencia de la minimización del riesgo empírico con respecto a $\mathcal{F}$.

El infinito queda muy lejos

¿Qué podemos decir sobre lo que ocurre después de observar solo un número finito de puntos de datos?
Detengámonos en la probabilidad del Teorema anterior:

$$P \left(\sup_{f \in \mathcal{F}} |\mathcal{R}(f) - \mathcal{R}_{\text{emp}}(f)| > \varepsilon \right).$$

El infinito queda muy lejos

¿Qué podemos decir sobre lo que ocurre después de observar solo un número finito de puntos de datos?
Detengámonos en la probabilidad del Teorema anterior:

$$P\left(\sup_{f \in \mathcal{F}} |\mathcal{R}(f) - \mathcal{R}_{\text{emp}}(f)| > \varepsilon\right).$$

Consideremos entonces un espacio de funciones finito. Sea $\mathcal{F}_m = \{f_1, f_2, \dots, f_m\}$ un conjunto de m funciones. Cada una de las funciones $f_i \in \mathcal{F}_m$ satisface la ley estándar de los grandes números en la forma de la cota de Chernoff:

$$P(|R(f_i) - \mathcal{R}_{\text{emp}}(f_i)| \geq \varepsilon) \leq 2 \exp(-2n\varepsilon^2).$$

Ahora queremos transformar estas afirmaciones sobre funciones individuales f_i en una ley uniforme de los grandes números. Dada la subatividad de la probabilidad, tenemos:

$$P \left(\sup_{f \in \mathcal{F}_m} |\mathcal{R}(f) - \mathcal{R}_{\text{emp}}(f)| \geq \varepsilon \right) \leq \sum_{i=1}^m P(|R(f_i) - \mathcal{R}_{\text{emp}}(f_i)| \geq \varepsilon).$$

Ahora queremos transformar estas afirmaciones sobre funciones individuales f_i en una ley uniforme de los grandes números. Dada la subatividad de la probabilidad, tenemos:

$$P\left(\sup_{f \in \mathcal{F}_m} |\mathcal{R}(f) - \mathcal{R}_{\text{emp}}(f)| \geq \varepsilon\right) \leq \sum_{i=1}^m P(|R(f_i) - \mathcal{R}_{\text{emp}}(f_i)| \geq \varepsilon).$$

Y aplicando la cota de Chernoff a cada término en la suma, obtenemos:

$$P\left(\sup_{f \in \mathcal{F}_m} |\mathcal{R}(f) - \mathcal{R}_{\text{emp}}(f)| \geq \varepsilon\right) \leq m (2 \exp(-2n\varepsilon^2)).$$

Ahora queremos transformar estas afirmaciones sobre funciones individuales f_i en una ley uniforme de los grandes números. Dada la subatividad de la probabilidad, tenemos:

$$P\left(\sup_{f \in \mathcal{F}_m} |\mathcal{R}(f) - \mathcal{R}_{\text{emp}}(f)| \geq \varepsilon\right) \leq \sum_{i=1}^m P(|R(f_i) - \mathcal{R}_{\text{emp}}(f_i)| \geq \varepsilon).$$

Y aplicando la cota de Chernoff a cada término en la suma, obtenemos:

$$P\left(\sup_{f \in \mathcal{F}_m} |\mathcal{R}(f) - \mathcal{R}_{\text{emp}}(f)| \geq \varepsilon\right) \leq m (2 \exp(-2n\varepsilon^2)).$$

Como m es constante

$$2m \exp(-2n\varepsilon^2) \xrightarrow{n \rightarrow \infty} 0$$

Ahora queremos transformar estas afirmaciones sobre funciones individuales f_i en una ley uniforme de los grandes números. Dada la subatividad de la probabilidad, tenemos:

$$P\left(\sup_{f \in \mathcal{F}_m} |\mathcal{R}(f) - \mathcal{R}_{\text{emp}}(f)| \geq \varepsilon\right) \leq \sum_{i=1}^m P(|R(f_i) - \mathcal{R}_{\text{emp}}(f_i)| \geq \varepsilon).$$

Y aplicando la cota de Chernoff a cada término en la suma, obtenemos:

$$P\left(\sup_{f \in \mathcal{F}_m} |\mathcal{R}(f) - \mathcal{R}_{\text{emp}}(f)| \geq \varepsilon\right) \leq m (2 \exp(-2n\varepsilon^2)).$$

Como m es constante

$$2m \exp(-2n\varepsilon^2) \xrightarrow{n \rightarrow \infty} 0$$

Por lo tanto, la minimización del riesgo empírico sobre un conjunto finito de funciones es consistente con respecto a $\mathcal{F}_m$.

En la práctica, nuestros espacios de funciones serán infinitos.

En la práctica, nuestros espacios de funciones serán infinitos.

Veremos que podemos reemplazar a m por un valor que depende de cada tipo de espacio funcional y que, de ser finito, será necesariamente polinómico, lo que nos permitirá obtener cotas de generalización.

En la práctica, nuestros espacios de funciones serán infinitos.

Veremos que podemos reemplazar a m por un valor que depende de cada tipo de espacio funcional y que, de ser finito, será necesariamente polinómico, lo que nos permitirá obtener cotas de generalización.

Llamaremos a dicha cantidad, la *dimensión VC*.



Vladimir Vapnik



Alexey Chervonenkis

Simetrización

Como no podemos calcular directamente $\mathcal{R}$, deseáramos acotar la ecuación

$$\sup_{f \in \mathcal{F}} |\mathcal{R}(f) - \mathcal{R}_{\text{emp}}(f)|$$

por una cantidad que dependa de valores empíricos en su totalidad.

Simetrización

Como no podemos calcular directamente $\mathcal{R}$, deseáramos acotar la ecuación

$$\sup_{f \in \mathcal{F}} |\mathcal{R}(f) - \mathcal{R}_{\text{emp}}(f)|$$

por una cantidad que dependa de valores empíricos en su totalidad.

Vamos a necesitar una muestra fantasma.



Lema de Simetrización

Sea $\mathcal{F}$ el espacio de funciones definido por un algoritmo de aprendizaje. Sean $(X_i, Y_i)_{i=1, \dots, m}$, $(X'_i, Y'_i)_{i=1, \dots, m}$ muestras aleatorias iid. Dada $f \in \mathcal{F}$, sean $\mathcal{R}(f)$ su riesgo, $\mathcal{R}_{\text{emp}}(f)$ su riesgo empírico sobre la primera muestra y $\mathcal{R}'_{\text{emp}}(f)$ el riesgo sobre la segunda. Entonces, para cualquier $\varepsilon > 0$ tal que $m \geq \frac{2}{\varepsilon^2}$, se cumple que

$$P \left(\sup_{f \in \mathcal{F}} |\mathcal{R}(f) - \mathcal{R}_{\text{emp}}(f)| > \varepsilon \right) \leq 2P \left(\sup_{f \in \mathcal{F}} |\mathcal{R}_{\text{emp}}(f) - \mathcal{R}'_{\text{emp}}(f)| > \frac{\varepsilon}{2} \right).$$

Este lema nos permite trabajar con eventos que dependen únicamente de las muestras observadas.


Fragmentación

Notemos que, incluso si $\mathcal{F}$ contiene un número infinito de funciones, las diferentes formas en que estas pueden clasificar un conjunto de entrenamiento de n puntos de muestra es finita.

Fragmentación

Notemos que, incluso si $\mathcal{F}$ contiene un número infinito de funciones, las diferentes formas en que estas pueden clasificar un conjunto de entrenamiento de n puntos de muestra es finita.

En efecto, para cualquier punto de entrenamiento dado en la muestra, una función puede tomar solo los valores -1 o $+1$.



Dos funciones que separan de igual manera a un par de puntos.

Definición

Sean $\mathcal{F}$ una clase de funciones y sea Z_n un conjunto de n puntos etiquetados, donde

$$Z_n := \{(X_1, Y_1), \dots, (X_n, Y_n)\}.$$

Definimos la relación $\sim$ sobre $\mathcal{F}$:

$$f_1 \sim f_2 \quad \text{si} \quad f_1(X_i) = f_2(X_i) \quad \forall i = 1, \dots, n.$$

Definición

Sean $\mathcal{F}$ una clase de funciones y sea Z_n un conjunto de n puntos etiquetados, donde

$$Z_n := \{(X_1, Y_1), \dots, (X_n, Y_n)\}.$$

Definimos la relación $\sim$ sobre $\mathcal{F}$:

$$f_1 \sim f_2 \quad \text{si} \quad f_1(X_i) = f_2(X_i) \quad \forall i = 1, \dots, n.$$

Observación

La relación $\sim$ es una relación de equivalencia sobre $\mathcal{F}$. Luego, para una muestra fija, define una partición sobre $\mathcal{F}$.

Definición


Definimos el **conjunto de fragmentación** $\mathcal{F}_{Z_n}$ a cualquier conjunto de representantes de $\mathcal{F}$ bajo la relación de equivalencia $\sim$ para la muestra Z_n .

Fragmentación

Definición

Definimos el **conjunto de fragmentación** $\mathcal{F}_{Z_n}$ a cualquier conjunto de representantes de $\mathcal{F}$ bajo la relación de equivalencia $\sim$ para la muestra Z_n .

Consideremos el espacio $\mathbb{R}^2$ y sea $\mathcal{F} = \{f : f(x) = \alpha x + \beta; \alpha, \beta \in \mathbb{R}\}$, el espacio de funciones lineales.



Definición

Dado un espacio muestral X y una muestra **cualquiera** de tamaño n , denotada por

$$Z_n := \{(X_1, Y_1), \dots, (X_n, Y_n)\},$$

definimos el **coeficiente de fragmentación** del espacio funcional $\mathcal{F}$ como:

$$\mathcal{N}(\mathcal{F}, n) = \max_{Z_n} \{|\mathcal{F}_{Z_n}|\} = \max_{\{X_1, \dots, X_n\}} \{|\mathcal{F}_{\{X_1, \dots, X_n\}}| \mid X_1, \dots, X_n \in X\}.$$

Definición

Dado un espacio muestral X y una muestra **cualquiera** de tamaño n , denotada por

$$Z_n := \{(X_1, Y_1), \dots, (X_n, Y_n)\},$$

definimos el **coeficiente de fragmentación** del espacio funcional $\mathcal{F}$ como:

$$\mathcal{N}(\mathcal{F}, n) = \max_{Z_n} \{|\mathcal{F}_{Z_n}|\} = \max_{\{X_1, \dots, X_n\}} \{|\mathcal{F}_{\{X_1, \dots, X_n\}}| \mid X_1, \dots, X_n \in X\}.$$

Definición

Si $\mathcal{N}(\mathcal{F}, n) = 2^n$, existe al menos una muestra de tamaño n que puede ser separada de todas las formas posibles por funciones en $\mathcal{F}$. En este caso, decimos que la clase de funciones $\mathcal{F}$ *fragmenta* al conjunto de n puntos.

El Coeficiente de Fragmentación y la Consistencia

Consideremos una muestra de $2n$ puntos. Volviendo al lema de simetrización, tenemos que

$$P\left(\sup_{f \in \mathcal{F}} |R(f) - R_{\text{emp}}(f)| > \varepsilon\right) \leq 2P\left(\sup_{f \in \mathcal{F}} |R_{\text{emp}}(f) - R'_{\text{emp}}(f)| > \frac{\varepsilon}{2}\right)$$

El Coeficiente de Fragmentación y la Consistencia

Consideremos una muestra de $2n$ puntos. Volviendo al lema de simetrización, tenemos que

$$\begin{aligned} P\left(\sup_{f \in \mathcal{F}} |R(f) - R_{\text{emp}}(f)| > \varepsilon\right) &\leq 2P\left(\sup_{f \in \mathcal{F}} |R_{\text{emp}}(f) - R'_{\text{emp}}(f)| > \frac{\varepsilon}{2}\right) \\ &= 2P\left(\sup_{f \in \mathcal{F}_{Z_{2n}}} |R_{\text{emp}}(f) - R'_{\text{emp}}(f)| > \frac{\varepsilon}{2}\right) \end{aligned}$$

El Coeficiente de Fragmentación y la Consistencia

Consideremos una muestra de $2n$ puntos. Volviendo al lema de simetrización, tenemos que

$$\begin{aligned} P\left(\sup_{f \in \mathcal{F}} |R(f) - R_{\text{emp}}(f)| > \varepsilon\right) &\leq 2P\left(\sup_{f \in \mathcal{F}} |R_{\text{emp}}(f) - R'_{\text{emp}}(f)| > \frac{\varepsilon}{2}\right) \\ &= 2P\left(\sup_{f \in \mathcal{F}_{Z_{2n}}} |R_{\text{emp}}(f) - R'_{\text{emp}}(f)| > \frac{\varepsilon}{2}\right) \\ &\leq 2\mathcal{N}(\mathcal{F}, n) \cdot \exp\left(\frac{-n\varepsilon^2}{4}\right). \end{aligned}$$

El Coeficiente de Fragmentación y la Consistencia

Teorema

La minimización del riesgo empírico es consistente con respecto a un espacio de funciones $\mathcal{F}$ si y solo si

$$\frac{\log(\mathcal{N}(\mathcal{F}, n))}{n} \rightarrow 0 \quad \text{cuando } n \rightarrow \infty.$$

El Coeficiente de Fragmentación y la Consistencia

Teorema

La minimización del riesgo empírico es consistente con respecto a un espacio de funciones $\mathcal{F}$ si y solo si

$$\frac{\log(\mathcal{N}(\mathcal{F}, n))}{n} \rightarrow 0 \quad \text{cuando } n \rightarrow \infty.$$

Corolario 1

Si $\mathcal{N}(\mathcal{F}, n)$ es polinómica, entonces la minimización del riesgo empírico es consistente con respecto a $\mathcal{F}$.

El Coeficiente de Fragmentación y la Consistencia

Teorema

La minimización del riesgo empírico es consistente con respecto a un espacio de funciones $\mathcal{F}$ si y solo si

$$\frac{\log(\mathcal{N}(\mathcal{F}, n))}{n} \rightarrow 0 \quad \text{cuando } n \rightarrow \infty.$$

Corolario 1

Si $\mathcal{N}(\mathcal{F}, n)$ es polinómica, entonces la minimización del riesgo empírico es consistente con respecto a $\mathcal{F}$.

Corolario 2

Si $\mathcal{N}(\mathcal{F}, n) = 2^n$, entonces la minimización del riesgo empírico no es consistente con respecto a $\mathcal{F}$. En particular, no es consistente con respecto al espacio de todas los clasificadores posibles $\mathcal{F}_{all}$.

Definición

La dimensión VC de una clase de funciones $\mathcal{F}$ es el tamaño máximo de una muestra que puede ser fragmentada por $\mathcal{F}$, es decir:

$$VC(\mathcal{F}) = \max\{n \in \mathbb{N} \mid \mathcal{N}(\mathcal{F}, n) = 2^n\}.$$

Si no existe tal máximo, definimos $VC(\mathcal{F}) = \infty$.

La dimensión VC

Definición

La dimensión VC de una clase de funciones $\mathcal{F}$ es el tamaño máximo de una muestra que puede ser fragmentada por $\mathcal{F}$, es decir:

$$VC(\mathcal{F}) = \max\{n \in \mathbb{N} \mid \mathcal{N}(\mathcal{F}, n) = 2^n\}.$$

Si no existe tal máximo, definimos $VC(\mathcal{F}) = \infty$.

Teorema

La dimensión VC del espacio de funciones lineales en $\mathbb{R}^2$ es 3.

La dimensión VC

Definición

La dimensión VC de una clase de funciones $\mathcal{F}$ es el tamaño máximo de una muestra que puede ser fragmentada por $\mathcal{F}$, es decir:

$$VC(\mathcal{F}) = \max\{n \in \mathbb{N} \mid \mathcal{N}(\mathcal{F}, n) = 2^n\}.$$

Si no existe tal máximo, definimos $VC(\mathcal{F}) = \infty$.

Teorema

La dimensión VC del espacio de funciones lineales en $\mathbb{R}^2$ es 3.

Teorema

La dimensión VC del espacio de funciones lineales en $\mathbb{R}^d$ es $d + 1$.

Lema

Sea $\mathcal{F}$ una clase de funciones con dimensión VC finita. Entonces

$$\mathcal{N}(\mathcal{F}, n) \leq \sum_{i=0}^{\text{VC}(\mathcal{F})} \binom{n}{i}, \quad \forall n \in \mathbb{N}.$$

En particular, para $n \geq \text{VC}(\mathcal{F})$ se tiene que

$$\mathcal{N}(\mathcal{F}, n) \leq \left(\frac{e \cdot n}{\text{VC}(\mathcal{F})} \right)^{\text{VC}(\mathcal{F})}.$$

La dimensión VC

Si $n \geq VC(\mathcal{F})$, el coeficiente de fragmentación se comporta como una función polinómica del tamaño de la muestra n .

La dimensión VC

Si $n \geq VC(\mathcal{F})$, el coeficiente de fragmentación se comporta como una función polinómica del tamaño de la muestra n .

Por los resultados de la sección anterior, esto implica la consistencia de la minimización del riesgo empírico.

La dimensión VC

Si $n \geq VC(\mathcal{F})$, el coeficiente de fragmentación se comporta como una función polinómica del tamaño de la muestra n .

Por los resultados de la sección anterior, esto implica la consistencia de la minimización del riesgo empírico.

Si la dimensión VC es infinita, para cada n existe alguna muestra que puede ser fragmentada por $\mathcal{F}$.

La dimensión VC

Si $n \geq VC(\mathcal{F})$, el coeficiente de fragmentación se comporta como una función polinómica del tamaño de la muestra n .

Por los resultados de la sección anterior, esto implica la consistencia de la minimización del riesgo empírico.

Si la dimensión VC es infinita, para cada n existe alguna muestra que puede ser fragmentada por $\mathcal{F}$.

Teorema

La minimización del riesgo empírico es consistente con respecto a una clase de funciones $\mathcal{F}$ si y solo si la dimensión VC de $\mathcal{F}$ es finita.

Límites y panorama actual

No hay almuerzos gratis y la paradoja moderna

No hay almuerzos gratis

¿Cuál de todos los clasificadores consistentes es *el mejor* clasificador?

No hay almuerzos gratis

¿Cuál de todos los clasificadores consistentes es *el mejor* clasificador?

¿Existe un clasificador universalmente bueno?

No hay almuerzos gratis

¿Cuál de todos los clasificadores consistentes es *el mejor* clasificador?

¿Existe un clasificador universalmente bueno?

No solamente no existe un clasificador universalmente bueno, sino que, en promedio sobre todas las distribuciones posibles, todos los clasificadores son equivalentes.

El Teorema de la chancha y los veinte

Sea $\varepsilon > 0$. Para cualquier entero n y cualquier regla de clasificación f_n , existe una distribución $P(X, Y)$ con riesgo bayesiano $\mathcal{R}(f_{Bayes}) = 0$ tal que:


$$\mathbb{E}[\ell(X, Y, f_n)] \geq \frac{1}{2} - \varepsilon.$$

La Paradoja Moderna: ¿Qué Dice la Teoría?

En la práctica, los modelos de aprendizaje profundo modernos son **extremadamente sobreparametrizados**. Por ejemplo, GPT-4: $\sim 1,8 \text{ T}$ parámetros, $n \ll$ parámetros. Las cotas VC serían **astronómicamente grandes** ... y sin embargo, **generalizan**.

La Paradoja Moderna: ¿Qué Dice la Teoría?

En la práctica, los modelos de aprendizaje profundo modernos son **extremadamente sobreparametrizados**. Por ejemplo, GPT-4: $\sim 1,8$ T parámetros, $n \ll$ parámetros. Las cotas VC serían **astronómicamente grandes** ... y sin embargo, **generalizan**.



Fenómeno de “doble descenso”: el error *vuelve a bajar* tras la sobreparametrización.

1. Doble descenso

El riesgo de prueba alcanza un pico en el umbral de interpolación y luego vuelve a caer cuando aumenta la capacidad.

La sobreparametrización permite que la optimización elija **funciones más regulares** pese a la enorme capacidad disponible.

Reconciliar teoría y realidad

1. Doble descenso

El riesgo de prueba alcanza un pico en el umbral de interpolación y luego vuelve a caer cuando aumenta la capacidad.

La sobreparametrización permite que la optimización elija **funciones más regulares** pese a la enorme capacidad disponible.

2. Sesgo implícito

El espacio de hipótesis $\mathcal{F}$ es nominalmente enorme, pero la optimización (SGD) actúa como un **regularizador implícito**.

Selecciona soluciones en subregiones estrechas, estables o de norma mínima dentro del paisaje de pérdida.

Reconciliar teoría y realidad

1. Doble descenso

El riesgo de prueba alcanza un pico en el umbral de interpolación y luego vuelve a caer cuando aumenta la capacidad.

La sobreparametrización permite que la optimización elija **funciones más regulares** pese a la enorme capacidad disponible.

2. Sesgo implícito

El espacio de hipótesis $\mathcal{F}$ es nominalmente enorme, pero la optimización (SGD) actúa como un **regularizador implícito**.

Selecciona soluciones en subregiones estrechas, estables o de norma mínima dentro del paisaje de pérdida.

3. Geometría de los datos

Las cotas de peor caso son demasiado conservadoras. Los datos reales de texto e imágenes se concentran en **variedades** de alta dimensión.

La complejidad efectiva escala con la dimensión intrínseca de los datos, no con el número de parámetros.

1. Doble descenso

El riesgo de prueba alcanza un pico en el umbral de interpolación y luego vuelve a caer cuando aumenta la capacidad.

La sobreparametrización permite que la optimización elija **funciones más regulares** pese a la enorme capacidad disponible.

2. Sesgo implícito

El espacio de hipótesis $\mathcal{F}$ es nominalmente enorme, pero la optimización (SGD) actúa como un **regularizador implícito**.

Selecciona soluciones en subregiones estrechas, estables o de norma mínima dentro del paisaje de pérdida.

3. Geometría de los datos

Las cotas de peor caso son demasiado conservadoras. Los datos reales de texto e imágenes se concentran en **variedades** de alta dimensión.

La complejidad efectiva escala con la dimensión intrínseca de los datos, no con el número de parámetros.

Cambio conceptual: pasar de cotas uniformes globales sobre $\mathcal{F}$ a estabilidad algorítmica, geometría local y medidas dependientes de los datos.

- von Luxburg, U. & Schölkopf, B. (2008). *Statistical Learning Theory: Models, Concepts and Results*.
- Vapnik, V. N. (1995). *The Nature of Statistical Learning Theory*. Springer-Verlag.
- Vapnik, V. N. (1998). *Statistical Learning Theory*. Wiley.
- Devroye, L., Györfi, L. & Lugosi, G. (1996). *A Probabilistic Theory of Pattern Recognition*. Springer.
- Schölkopf, B. & Smola, A. J. (1996). *Learning with Kernels*. MIT Press.
- Casella, G. & Berger, R. L. (2002). *Statistical Inference*. Duxbury.
- Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer.
- Vapnik, V. N. & Chervonenkis, A. Ya. (1971). On the uniform convergence of relative frequencies of events to their probabilities.
- Khinchin, A. Ya. (1956). On basic theorems of information theory.
- Feller, W. (1957). *Introduction to Probability Theory and its Applications*. Wiley.
- Billingsley, P. (1995). *Probability and Measure*. 3rd ed., Wiley.
- Abu-Mostafa, Y. S., Magdon-Ismael, M. & Lin, H.-T. (2012). *Learning From Data*. AMLBook.
- Minsky, M. & Papert, S. (1969). *Perceptrons: An Introduction to Computational Geometry*. MIT Press.

“Examinadlo todo; retened lo bueno.”

San Pablo, 1 Tesalonicenses 5:21

Muchas gracias

