Fundamentos Matemáticos del Aprendizaje Automático

Nicolas Silva Nash

Departamento de Matemática
Universidad Nacional del Comahue

Director: Dr. Luis Nowak **Codirectora:** Dra. Alejandra Perini

Defensa de Tesina de Licenciatura

El Rigor en la Ciencia

> *"... las Generaciones Siguientes entendieron que ese dilatado Mapa era Inútil."*
>
> — Jorge Luis Borges,
> *Del Rigor en la Ciencia*

- Un mapa a escala 1:1 **replica** la realidad; no la simplifica.
- Un modelo que memoriza los datos es igualmente inútil.

Aprender $\neq$ Memorizar

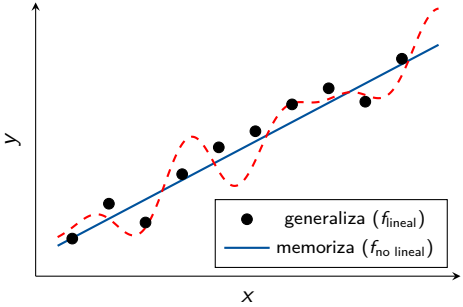

Inspirado en Figura 2.1 de la tesina.

Formalizando el Terreno de Juego

- **Espacio de entrada:** $\mathcal{X}$
- **Espacio de etiquetas:** $\mathcal{Y} = \{-1, +1\}$
- **La gran incógnita:** distribución conjunta

$$P(X, Y) \text{ sobre } \mathcal{X} \times \mathcal{Y}$$

desconocida e irrestricta

- **Lo que observamos:** muestra i.i.d.

$$(X_1, Y_1), \ldots, (X_n, Y_n) \overset{\text{iid}}{\sim} P$$

Objetivo

Construir $f : \mathcal{X} \to \mathcal{Y}$ que generalice a puntos **no vistos**.

Diferencia clave con Estadística clásica

Somos **agnósticos** respecto a P:

no asumimos ninguna forma paramétrica.

La vemos *solo* a través de la muestra finita.

¿Qué Significa Equivocarse?

Función de pérdida 0-1:

$$\ell(X, Y, f(X)) \;:=\; \begin{cases} 1 & \text{si } f(X) \neq Y \\ 0 & \text{si } f(X) = Y \end{cases}$$

Riesgo Real — nuestro Santo Grial:

$$\mathcal{R}(f) \;:=\; \mathbb{E}_P\big[\,\ell(X, Y, f(X))\,\big]$$

El mejor clasificador posible minimiza $\mathcal{R}$.

El obstáculo central

Calcular $\mathcal{R}(f)$ requiere conocer $P(X, Y)\ldots$

que no conocemos.

Lo que sí podemos hacer

Aproximar $\mathcal{R}(f)$ con la **pérdida promedio** sobre los datos de entrenamiento:

$$\mathcal{R}(f) \;\approx\; \mathcal{R}_{\text{emp}}(f)$$

El Ideal Inalcanzable: f_{Bayes}

Clasificador de Bayes:

$$f_{\text{Bayes}}(x) := \begin{cases} +1 & \text{si } P(Y=1 \mid X=x) \geq \frac{1}{2} \\ -1 & \text{en otro caso} \end{cases}$$

- Minimiza $\mathcal{R}(f)$ sobre **todas** las funciones medibles.
- Asigna siempre la etiqueta más probable dado x.
- Es el **techo teórico** de cualquier clasificador.

¿Por qué es inalcanzable?

Requiere conocer $P(Y \mid X)$, **que es exactamente lo que desconocemos**.

Problema central

Dado $\{(X_i, Y_i)\}_{i=1}^n$ i.i.d. de P, construir f tal que

$$\mathcal{R}(f) \xrightarrow{n\to\infty} \mathcal{R}(f_{\text{Bayes}})$$

El Atajo Empírico: Riesgo Empírico

Riesgo Empírico (lo que *sí* podemos calcular):

$$\mathcal{R}_{\text{emp}}(f) \;:=\; \frac{1}{n}\sum_{i=1}^{n} \ell\big(X_i,\; Y_i,\; f(X_i)\big)$$

Principio ERM (Minimización del Riesgo Empírico):

$$f_n \;:=\; \arg\min_{f\in\mathcal{F}} \; \mathcal{R}_{\text{emp}}(f)$$

La motivación proviene de la **Ley de los Grandes Números**:

$$\frac{1}{n}\sum_{i=1}^{n} \xi_i \;\xrightarrow{n\to\infty}\; \mathbb{E}[\xi] \qquad (\xi_i \text{ i.i.d.})$$

La promesa

Para f **fija**, la LGN garantiza:

$$\mathcal{R}_{\text{emp}}(f) \;\xrightarrow{n\to\infty}\; \mathcal{R}(f)$$

Más datos $\Rightarrow$ mejor estimación.

La trampa oculta

Nuestra f_n **depende de los datos**.

La LGN aplica a funciones *fijas*, no a funciones que cambian con la muestra.

El Colapso de la Memorización: $\mathcal{F}_{\text{all}}$

El clasificador "tramposo" (búsqueda irrestricta en $\mathcal{F}_{\text{all}}$):

$$f_n(X) := \begin{cases} Y_i & \text{si } X = X_i \text{ para algún } i \\ +1 & \text{en otro caso} \end{cases}$$

- $\mathcal{R}_{\text{emp}}(f_n) = 0$ (perfecto en train)
- $\mathcal{R}(f_n) = \frac{1}{2}$ (moneda al aire en test)

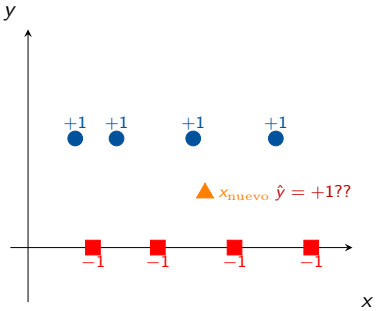

f_n memoriza el train; ignora el test.

Diagnóstico

Sobreajuste catastrófico.
El algoritmo aprendió los datos, no la regla.

El Dilema de la Complejidad

Descomposición del exceso de riesgo:

$$\underbrace{\mathcal{R}(f_n) - \mathcal{R}(f_{\text{Bayes}})}_{\text{lo que queremos reducir}}$$

$$= \underbrace{\mathcal{R}(f_n) - \mathcal{R}(f_{\mathcal{F}})}_{\text{error de estimación}} + \underbrace{\mathcal{R}(f_{\mathcal{F}}) - \mathcal{R}(f_{\text{Bayes}})}_{\text{error de aproximación}}$$

- **Aprox.:** $\mathcal{F}$ pequeño $\Rightarrow$ alto sesgo (subajuste).
- **Estim.:** $\mathcal{F}$ grande $\Rightarrow$ alta varianza (sobreajuste).

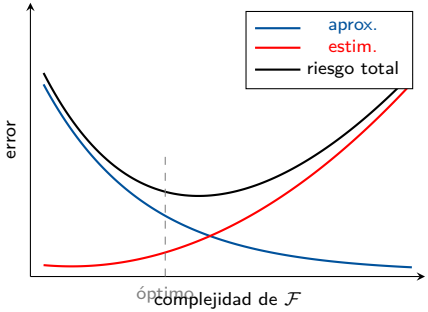

Inspirado en Figura 2.3 de la tesina.

La Necesidad de un Sesgo Inductivo

Conclusión del bloque

Para que ERM sea **consistente**, el espacio $\mathcal{F}$ debe ser suficientemente restringido.

- $\mathcal{F} = \mathcal{F}_{\text{all}} \Rightarrow$ inconsistencia garantizada.
- $\mathcal{F}$ pequeño (e.g., funciones lineales) $\Rightarrow$ bajo error de estimación.
- Todo aprendizaje exitoso impone un **sesgo inductivo**.

No existe conocimiento sin suposición.
La pregunta es cuál suposición elegir.

Pregunta puente

¿Cómo **medir formalmente** si un espacio $\mathcal{F}$ es lo suficientemente "restringido" para que ERM no nos mienta?

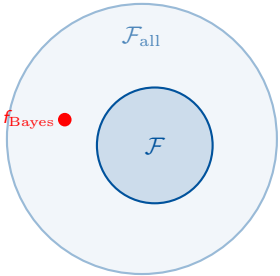

Restringir $\Leftrightarrow$ controlar la capacidad

$\longrightarrow$ **Teoría VC**

La Ley que nos Quedó Chica: Convergencia Uniforme

LGN para f fija (lo que ya teníamos):

$$\mathcal{R}_{\text{emp}}(f) \xrightarrow{n\to\infty} \mathcal{R}(f) \qquad \checkmark$$

Lo que realmente necesitamos:

$$\sup_{f\in\mathcal{F}} \left|\mathcal{R}(f) - \mathcal{R}_{\text{emp}}(f)\right| \xrightarrow{n\to\infty} 0 \qquad (?)$$

Convergencia *simultánea* para **todas** las $f \in \mathcal{F}$.

¿Por qué la LGN no alcanza?

$f_n = \arg\min_{f\in\mathcal{F}} \mathcal{R}_{\text{emp}}(f)$ **depende de los datos**.

La LGN aplica a funciones *fijas*, no a funciones que cambian con la muestra.

Lo que hay que probar

$$P\left(\sup_{f\in\mathcal{F}} \left|\mathcal{R}(f) - \mathcal{R}_{\text{emp}}(f)\right| > \varepsilon\right) \xrightarrow{n\to\infty} 0$$

para todo $\varepsilon > 0$.

Geometría de la Capacidad: Coeficiente de Fragmentación

Coeficiente de fragmentación

$$N(\mathcal{F},\, n) \;:=\; \max_{x_1,\ldots,x_n \in \mathcal{X}} \left| \left\{ (f(x_1), \ldots, f(x_n)) : f \in \mathcal{F} \right\} \right|$$

- Reduce $\mathcal{F}$ (infinito) a un conteo **combinatorio finito**.
- $N(\mathcal{F}, n) \leq 2^n$ siempre; la igualdad $=$ *fragmentación completa*.
- Clasificadores lineales en $\mathbb{R}^2$:

$$N(\mathcal{F},\, 3) = 8 = 2^3 \quad \checkmark$$

4 de 8 dicotomías posibles con clasificadores lineales:

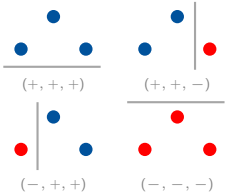

$N(\mathcal{F},\, 3) = 2^3 = 8$: fragmentación completa.

El Límite del Aprendizaje: La Dimensión VC

Dimensión VC

$$\mathrm{VC}(\mathcal{F}) \;:=\; \text{máx}\left\{ n \in \mathbb{N} \;\middle|\; N(\mathcal{F},\, n) = 2^n \right\}$$

El tamaño máximo de una muestra que $\mathcal{F}$ puede fragmentar *completamente*.

- Condensa la complejidad de $\mathcal{F}$ en un **número entero**.
- **Clasificadores lineales en** $\mathbb{R}^2$: $\mathrm{VC}(\mathcal{F}) = 3$.
- $\mathrm{VC}(\mathcal{F}) = \infty \Rightarrow$ sobreajuste garantizado ($\mathcal{F}_{\mathrm{all}}$).

4 puntos en configuración XOR: ningún clasificador lineal los fragmenta

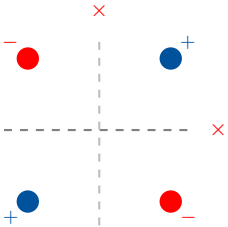

configuración XOR

$N(\mathcal{F}, 4) < 16 = 2^4 \;\Rightarrow\; \mathrm{VC}(\text{lin. en } \mathbb{R}^2) = 3$

El Truco Analítico: Lema de Simetrización

El obstáculo: la cota original depende de P:

$$P\left(\sup_{f\in\mathcal{F}}\left|\mathcal{R}(f)-\mathcal{R}_{\text{emp}}(f)\right|>\varepsilon\right)$$

$\mathcal{R}(f)=\mathbb{E}_P[\cdots]$: incalculable.

La idea: introducir una **muestra fantasma** S':

$$\left|\mathcal{R}(f)-\mathcal{R}_{\text{emp}}(f)\right| \lesssim \left|\mathcal{R}_{\text{emp}}(f)-\mathcal{R}'_{\text{emp}}(f)\right|$$

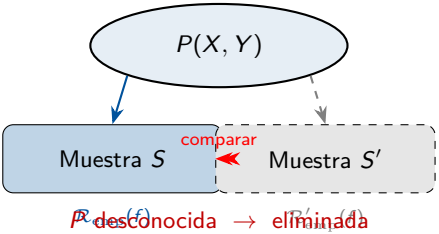

El resultado clave

$$P\left(\sup_f|\mathcal{R}-\mathcal{R}_{\text{emp}}|>\varepsilon\right)\leq 2\,P\left(\sup_f|\mathcal{R}_{\text{emp}}-\mathcal{R}'_{\text{emp}}|>\frac{\varepsilon}{2}\right)$$

La magia

Pasamos de comparar contra P (desconocida) a comparar **dos muestras finitas**: problema **combinatorio**, no probabilístico.

El Teorema Fundamental del Aprendizaje Estadístico

ERM es universalmente consistente

$$\iff \quad \mathrm{VC}(\mathcal{F}) < \infty$$

Hoja de ruta de la prueba

1. **Simetrización:** P desconocida $\to$ muestra fantasma S'.
2. **Permutaciones:** problema combinatorio sobre $2n$ puntos.
3. **Sauer–Shelah:** $N(\mathcal{F}, 2n) \leq \left(\frac{2n}{\mathrm{VC}(\mathcal{F})}\right)^{\mathrm{VC}(\mathcal{F})}$.
4. **Unión de eventos:** la cota total $\to 0$ si $\mathrm{VC} < \infty$.

Interpretación

Aprender es, fundamentalmente, un problema de capacidad finita.

- De intuición estadística ("no sobreajustar") a **garantía matemática estricta**.
- $\mathrm{VC}(\mathcal{F})$ cuantifica la riqueza estructural del modelo.

¿Existe un Algoritmo Maestro?

Hemos demostrado:

- ERM consistente $\iff \mathrm{VC}(\mathcal{F}) < \infty$.
- Con $\mathcal{F}$ adecuado, el error es acotable.
- El ideal teórico es f_{Bayes}.

Pregunta natural:

¿Existe f^* que, **en promedio sobre todas las distribuciones** $P(X, Y)$, supere a cualquier otro clasificador?

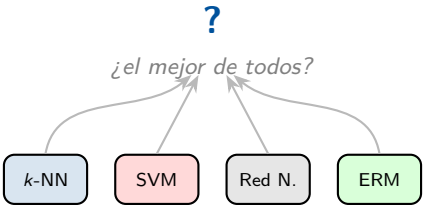

“Los Teoremas de la Chancha y los Veinte”

Teorema 4.3.1 (Devroye, 1982)

Sea $\varepsilon > 0$. Para cualquier $n \in \mathbb{N}$ y cualquier regla f_n, **existe** una distribución $P(X, Y)$ con $\mathcal{R}(f_{\text{Bayes}}) = 0$ tal que:

$$\mathbb{E}\left[\ell(X, Y, f_n)\right] \geq \frac{1}{2} - \varepsilon$$

- Por cada universo donde f_n triunfa, existe un universo “espejo” donde falla como una moneda.
- Promediado sobre **todas** las P: todo algoritmo rinde igual.
- No contradice consistencia: la distribución adversarial depende de n.

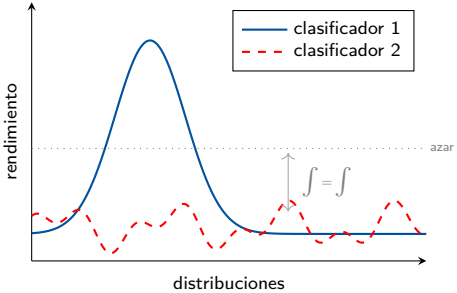

Área bajo ambas curvas es igual. Inspirado en Figura 4.2 de la tesina.

El Sesgo Inductivo: La Moraleja del Machine Learning

La lección central

Aprender "en el vacío" es **imposible**.

Para aprender, debemos **asumir**.

Sesgo inductivo

Restricción sobre el espacio de distribuciones o funciones que el algoritmo considera plausibles.

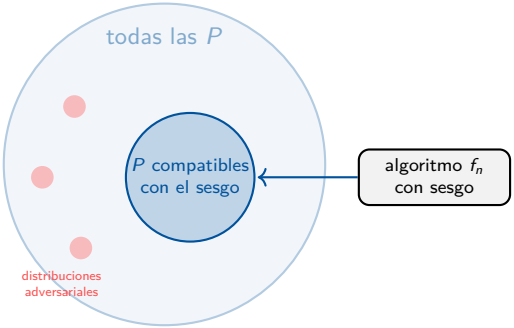

- k-**NN:** puntos cercanos tienen etiquetas similares.
- **SVM:** las clases son separables por un margen.
- **Red neuronal:** la función es aproximable por composición de no-linealidades.

La clave del éxito práctico

No existe el algoritmo perfecto: el éxito es elegir aquel cuyas **suposiciones** coincidan con la **física del problema**.

La Paradoja Moderna: ¿Qué Dice la Teoría?

El marco clásico predice

Si $\mathrm{VC}(\mathcal{F}) = d < \infty$, con alta probabilidad:

$$\mathcal{R}(f_n) \leq \hat{\mathcal{R}}_n(f_n) + O\left(\sqrt{\frac{d + \ln(1/\delta)}{n}}\right)$$

- **Capacidad alta** $\Rightarrow$ cota grande.
- **Sobreparametrización** $\Rightarrow$ sobreajuste inevitable.

Lo que observamos en la práctica

GPT-4: $\sim$1,8 T parámetros, $n \ll$ parámetros.

Las cotas VC serían **astronómicamente grandes**...

...y sin embargo, generalizan.

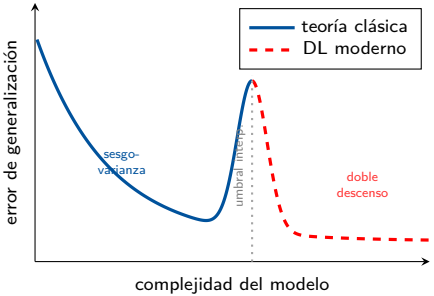

Fenómeno de "doble descenso": el error *vuelve a bajar* tras la sobreparametrización.

Leyes de Escalamiento: Fuerza Bruta → Necesidad Teórica

Empirismo a escala (Kaplan et al., 2020)

$$L(N) \approx \left(\frac{N_c}{N}\right)^{\alpha}, \quad \alpha \approx 0{,}076$$

La pérdida sigue una **ley de potencias** en parámetros N, tokens y cómputo.
Transformers, LLMs, modelos de difusión.

- **Hoy:** escalamos porque funciona empíricamente.
- **Mañana:** los límites físicos y económicos frenarán el escalado.
- **La teoría es el cuello de botella:** sin fundamentos de generalización para regímenes sobreparametrizados, avanzamos a ciegas.

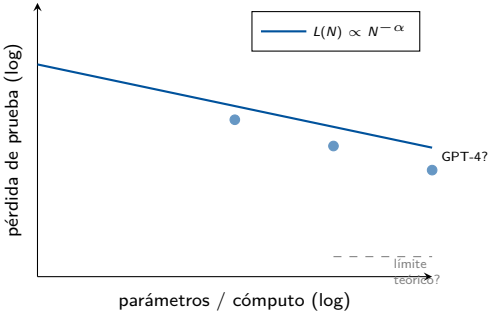

Ley de potencias empírica (Kaplan et al., 2020). Los valores son ilustrativos.

Fuerza — límites — Necesidad

“Dios mueve al jugador, y éste, la pieza.
¿Qué Dios detrás de Dios la trama empieza?”

Jorge Luis Borges, *Ajedrez*, 1960

Detrás de cada algoritmo, una pregunta matemática.

La tesina fue un paso; el camino sigue abierto.

Muchas gracias.

¿Preguntas?