

Fundamentos Matemáticos del Aprendizaje Automático

Nicolas Silva Nash

Departamento de Matemática
Universidad Nacional del Comahue

Director: Dr. Luis Nowak **Codirectora:** Dra. Alejandra Perini

Defensa de Tesina de Licenciatura

"[Funes] había aprendido sin esfuerzo el inglés, el francés, el portugués, el latín. Sospecho, sin embargo, que no era muy capaz de pensar. Pensar es olvidar diferencias, es generalizar, abstraer. En el abarrotado mundo de Funes no había sino detalles, casi inmediatos."

— Jorge Luis Borges,
Funes el memorioso

¿Qué Entendemos por Aprendizaje?

El aprendizaje es el proceso a través del cual pueden inferirse reglas generales a partir de ejemplos.


Nos interesa entender como una computadora puede resolver ciertos problemas sin conocer las reglas de antemano, solo a partir de ejemplos y a través de un algoritmo de aprendizaje.

Nos gustaría que la máquina aprenda no solo las reglas de los ejemplos dados, si no que pueda generalizarlas para ejemplos que todavía no vió.

Llamamos Machine Learning a la disciplina que se enfoca en el estudio y desarrollo de algoritmos que permiten a las máquinas aprender de los datos.

La consideramos una subdisciplina de la Inteligencia Artificial.

¿Qué Significa que una Máquina Aprenda?



Reconocimiento facial mediante landmarks geométricos.


- A partir de **ejemplos**, la máquina construye una regla de decisión.
- No se programa la respuesta: se **infiere** desde los datos.
- El desafío matemático: garantizar que la regla **generalice** a casos nuevos.

¿Cuándo y por qué funciona?

Clasificación: Planteo del Problema

Consideremos dos espacios de variables: X , llamado espacio de entrada, e Y , el espacio de etiquetas. En un problema de clasificación, deseamos poder etiquetar correctamente elementos de X con los valores de Y .

Por ejemplo, podríamos querer clasificar un conjunto de imágenes de animales en base a los distintos tipos de animales que aparecen en ellas.



Reconocimiento de distintos tipos de animales

Clasificación: Datos y Clasificador

Asumimos que entre el espacio de entrada y el espacio de etiquetas hay una distribución de probabilidad conjunta $P = P(X, Y)$.

Con el fin de aprender, a un algoritmo se le muestran ejemplos de imágenes y sus respectivas etiquetas $(X_1, Y_1), (X_2, Y_2), \dots, (X_n, Y_n)$, a partir de los cuales este debe encontrar una función $f : X \rightarrow Y$, que comete la menor cantidad de errores posibles.

A esta función f la llamamos clasificador.

A fin de simplificar la teoría, nos centraremos en el más sencillo de los problemas del Machine Learning, el de clasificación binaria. En este caso, tendremos dos categorías de etiquetas, por lo que

$$Y = \{-1, +1\}$$

Clasificación: Suposiciones básicas

- **No aplicamos restricciones sobre P :** no suponemos una forma paramétrica para la distribución que genera los datos.
- **Etiquetas no determinísticas:** modelamos Y mediante probabilidades condicionales $P(Y = 1 \mid X = x)$. Esto se debe a que:
 - Puede existir solapamiento entre las clases. (ej: imágenes lejanas de perros y gatos con características similares).
 - En la práctica, hay ruido en las etiquetas. (ej: distintos etiquetadores humanos no coincidiendo en si un email es spam; errores de etiquetado).
- **Muestreo iid:** los ejemplos se toman de manera independiente e idénticamente distribuida.
- **Distribución fija:** asumimos que el mecanismo que genera los datos no cambia entre entrenamiento y uso.
- **P desconocida:** solo accedemos a la distribución a través de una muestra finita de datos. El valor de la teoría estará en entender bajo qué condiciones podremos inferir algo sobre P .


Formalizando el Terreno de Juego

Objetivo

Construir $f : X \rightarrow Y$ que generalice a puntos **no vistos**.

Diferencia clave con Estadística clásica

Somos **agnósticos** respecto a P : no asumimos ninguna forma paramétrica.
Conocemos a la distribución P *solo* a través de la muestra finita.



¿Qué Significa Equivocarse?: Función de Pérdida

Para medir la efectividad de la función clasificadora, definimos una Función de Pérdida ℓ .
En el caso binario, la función más sencilla es

Función de pérdida 0-1

$$\ell(X, Y, f(X)) := \begin{cases} 1 & \text{si } f(X) \neq Y \\ 0 & \text{si } f(X) = Y \end{cases}$$

Por convención, una pérdida igual a 0 implica una clasificación perfecta y valores mayores implican peor clasificación.

¿Qué Significa Equivocarse?: Función de Riesgo

Mientras que la función de pérdida mide el error del clasificador en un punto individual $x \in X$, llamamos riesgo, R , del clasificador a la pérdida esperada sobre todos los datos generados por la distribución de probabilidad P

Riesgo

$$\mathcal{R}(f) := \mathbb{E}_P[\ell(X, Y, f(X))]$$

El mejor clasificador posible minimiza $\mathcal{R}$.

Es decir, el aprendizaje suele implicar un desafío de optimización en dónde deseamos hallar el mínimo de la función de riesgo.

Clasificador de Bayes:

$$f_{\text{Bayes}}(x) := \begin{cases} +1 & \text{si } P(Y = 1 \mid X = x) \geq \frac{1}{2} \\ -1 & \text{en otro caso} \end{cases}$$

- Minimiza $\mathcal{R}(f)$ sobre **todas** las funciones medibles.
- Asigna siempre la etiqueta más probable dado x .
- Es el **techo teórico** de cualquier clasificador.

¿Por qué es inalcanzable?

Requiere conocer $P(X, Y)$, **que es exactamente lo que desconocemos.**

Definición del problema de clasificación binaria

Si el clasificador de Bayes es incomputable en la práctica, ¿Qué utilidad tiene definirlo?
Lo hacemos porque nos permite definir el problema que estamos tratando.

Definición

Dado un conjunto de datos de entrenamiento $\{(X_1, Y_1), \dots, (X_n, Y_m)\}$ obtenidos iid de una distribución P , y dada una función de pérdida ℓ , deseamos construir una función clasificadora $f : X \rightarrow Y$ cuyo riesgo $\mathcal{R}(f)$ sea lo más cercano posible al riesgo de f_{Bayes} . Llamamos a este problema **clasificación binaria**.

Pero... ¿Cómo construimos esta función clasificadora?

Definición

Llamamos **algoritmo de aprendizaje** a todo procedimiento matemático que, dado un conjunto de datos de entrenamiento (X_i, Y_i) , devuelve una función clasificadora f sobre el espacio de entrada $\mathcal{X}$ y el espacio de etiquetas $\mathcal{Y}$ del que provienen los datos.

El algoritmo define la forma de la función clasificadora. En general, a través de este determinamos al espacio funcional $\mathcal{F}$ de donde extraemos los distintos clasificadores del proceso de aprendizaje.

Ejemplo: El perceptrón de Rosenblatt





Dado un conjunto de entrenamiento $S = \{(\mathbf{x}_i, y_i)\}_{i=1}^n \subset \mathbb{R}^d \times \{0, 1\}$, el Perceptrón se define como un clasificador binario $h : \mathbb{R}^d \rightarrow \{0, 1\}$ mediante la siguiente función:

$$h_{\mathbf{w},b}(\mathbf{x}) = \text{sgn}(\mathbf{w}^T \mathbf{x} > 0)$$

Donde $\mathbf{w} \in \mathbb{R}^d$ es el vector de pesos, $b \in \mathbb{R}$ es el sesgo (bias), y $\text{sgn}(\cdot)$ denota la función Signum. El aprendizaje de los parámetros se realiza a través de una regla de actualización iterativa. Para cada muestra $(\mathbf{x}_i, y_i)$, la actualización se define como:

$$\mathbf{w}^{(t+1)} \leftarrow \mathbf{w}^{(t)} + \eta(y_i - \hat{y}_i)\mathbf{x}_i$$

donde $\hat{y}_i = h_{\mathbf{w}^{(t)},b^{(t)}}(\mathbf{x}_i)$ es la predicción actual y $\eta \in (0, 1]$ es llamada la tasa de aprendizaje.



Consistencia

Sea $(X_i, Y_i)_{i \in \mathbb{N}}$ una sucesión infinita de puntos de entrenamiento que han sido tomados iid de una distribución P . Sea ℓ una función de pérdida. Por cada $n \in \mathbb{N}$, sea f_n un clasificador construido por algún algoritmo de aprendizaje usando los primeros n puntos de entrenamiento. Sea $\mathcal{F}$ el espacio funcional de todos los posibles clasificadores según el mecanismo de construcción del algoritmo. Entonces

- 1 El algoritmo de aprendizaje se dice consistente con respecto a $\mathcal{F}$ y a P si el riesgo $\mathcal{R}(f_n)$ converge en probabilidad al riesgo $\mathcal{R}(f_{\mathcal{F}})$ del mejor clasificador en $\mathcal{F}$. Esto es, que para todo $\varepsilon > 0$:

$$P(\mathcal{R}(f_n) - \mathcal{R}(f_{\mathcal{F}}) > \varepsilon) \rightarrow 0 \quad \text{cuando} \quad n \rightarrow \infty$$

- 2 El algoritmo de aprendizaje se dice Bayes-consistente con respecto a P si el riesgo $\mathcal{R}(f_n)$ converge en probabilidad al riesgo $\mathcal{R}(f_{\text{Bayes}})$ del clasificador bayesiano. Esto es, para todo $\varepsilon > 0$

$$P(\mathcal{R}(f_n) - \mathcal{R}(f_{\text{Bayes}}) > \varepsilon) \rightarrow 0 \quad \text{cuando} \quad n \rightarrow \infty$$

- 3 El algoritmo de aprendizaje se dice universalmente consistente con respecto a $\mathcal{F}$ si es consistente con respecto a $\mathcal{F}$ para toda distribución de probabilidad P .
- 4 El algoritmo de aprendizaje se dice universalmente Bayes-consistente si es Bayes-consistente para toda distribución de probabilidad P .

Hay muchas cosas que no podemos calcular

No somos capaces de hallar al clasificador de Bayes.

No podemos hallar explícitamente al mejor clasificador de un espacio funcional.

Ni siquiera podemos calcular el riesgo de un clasificador conocido.

...

¿Qué podemos hacer?

Lo que si podemos hacer, dado un conjunto de entrenamiento, es “contar” (o medir, en general, para problemas que no son de clasificación binaria) el número de errores del clasificador sobre los datos de entrenamiento.

A esta cantidad le daremos el nombre de riesgo empírico.

La veremos presente en la literatura también como error de entrenamiento.

Nuestro interés será ver bajo qué condiciones esta cantidad medible nos permite obtener conclusiones del riesgo real que no podemos observar.

La definimos a continuación.

Definición

Sea $(X_i, Y_i)_{i=1}^n$ un conjunto de datos de entrenamiento, donde cada (X_i, Y_i) es tomado iid de una distribución de probabilidad $P(X, Y)$. Sea ℓ una función de pérdida. Sea f_n un clasificador binario construido a partir de ejemplos, luego de ser presentado con los primeros n datos de entrenamiento. Entonces el **riesgo empírico** del clasificador f es la pérdida promedio sobre los datos de entrenamiento, es decir

$$R_{emp}(f) := \frac{1}{n} \sum_{i=1}^n \ell(X_i, Y_i, f(X_i))$$

El algoritmo de aprendizaje define la forma de la función clasificadora que construimos a partir de los datos de entrenamiento.

En general, buscamos la función f que minimiza el riesgo empírico para los datos que tenemos. Nos gustaría que el riesgo real se acercara al riesgo de Bayes de una porque queremos que sea un “buen” clasificador. Hemos llamado a esto **consistencia**.

También desearíamos que el riesgo empírico se halle “cerca” del real, porque podríamos inferir la calidad de nuestro clasificador para toda la distribución y no solo en los datos de entrenamiento. Llamamos a esta idea el **generalización**.


Generalización

Deseamos que

$$\mathcal{R}_{\text{emp}}(f) \approx \mathcal{R}(f)$$

es decir, que el clasificador se comporte de forma similar en los datos de entrenamiento y en los ejemplos que aún no vio, para que podamos afirmar cosas del riesgo real a partir de lo que podemos medir en el empírico.

Generalización



La Ley de los Grandes Números

En su forma más simple, la ley de los grandes números establece que, bajo condiciones suaves, la media de variables aleatorias ξ_i que han sido extraídas de manera *iid* a partir de una distribución de probabilidad P , converge a la media de la distribución subyacente cuando el tamaño de la muestra tiende a infinito:

$$\frac{1}{n} \sum_{i=1}^n \xi_i \rightarrow \mathbb{E}(\xi) \quad \text{cuando } n \rightarrow \infty.$$

Tomando $\xi_i = \ell(X_i, Y_i, f(X_i))$, **para una función fija f** , tenemos

$$\frac{1}{n} \sum_{i=1}^n \ell(X_i, Y_i, f(X_i)) \rightarrow \mathbb{E}(\ell(X, Y, f(X))) \quad \text{cuando } n \rightarrow \infty.$$

O lo que es lo mismo:

$$\mathcal{R}_{\text{emp}}^n(f) \rightarrow \mathcal{R}(f) \quad \text{cuando } n \rightarrow \infty.$$

La Cota de Chernoff-Hoeffding nos permite obtener una cota de probabilidad para la diferencia entre el riesgo empírico y el riesgo real de una función fija f . En particular, si $\xi_1, \dots, \xi_n$ son variables aleatorias independientes acotadas en el intervalo $[0, 1]$ con media $\mathbb{E}(\xi)$, entonces para cualquier $\varepsilon > 0$ se cumple que

$$P\left(\left|\frac{1}{n} \sum_{i=1}^n \xi_i - \mathbb{E}(\xi)\right| \geq \varepsilon\right) \leq 2 \exp(-2n\varepsilon^2).$$

Es decir, para una función fija f :

Cota de Chernoff-Hoeffding

$$P(|\mathcal{R}_{\text{emp}}(f) - \mathcal{R}(f)| \geq \varepsilon) \leq 2 \exp(-2n\varepsilon^2).$$

Un algoritmo de aprendizaje arroja una función distinta por cada ejemplo de entrenamiento que ve. Esto implica que, a medida que el número de elementos n en el conjunto de entrenamiento crece, la función que se define cambia.

Nos gustaría poder aplicar la Ley de los Grandes Números a esta función, pero no podemos porque no es fija.

Análogamente, la cota de Chernoff-Hoeffding no se puede aplicar directamente a nuestro caso porque cada punto nuevo cambia la función que estamos tratando.

Nuestro objetivo será entonces encontrar condiciones bajo las cuales podamos aplicar esta cota a funciones que no son fijas, sino que cambian con cada nuevo ejemplo de entrenamiento.

Esto efectivamente implica una generalización de la Ley de los Grandes Números, que se conoce como la **ley uniforme de los grandes números**.

Hacia una Ley Uniforme de los Grandes Números

Sea $\mathcal{F}$ un espacio funcional de clasificadores. Para poder dar certezas no para una, sino para cualquier función del espacio, debemos de ser capaces de acotar la diferencia entre el riesgo empírico y el riesgo real para todas las funciones del espacio. Queremos entonces hallar condiciones bajo las cuales se cumple que, para todo $\varepsilon > 0$,

$$\sup_{f \in \mathcal{F}} |\mathcal{R}(f) - \mathcal{R}_{\text{emp}}(f)| \leq \varepsilon.$$

Es claro que

$$P(|\mathcal{R}(f_n) - \mathcal{R}_{\text{emp}}(f_n)| \geq \varepsilon) \leq P\left(\sup_{f \in \mathcal{F}} |\mathcal{R}(f) - \mathcal{R}_{\text{emp}}(f)| \geq \varepsilon\right).$$

Decimos que la ley de los grandes números se cumple de manera uniforme sobre una clase de funciones $\mathcal{F}$ si, para todo $\varepsilon > 0$,

$$P\left(\sup_{f \in \mathcal{F}} |\mathcal{R}(f) - \mathcal{R}_{\text{emp}}(f)| \geq \varepsilon\right) \rightarrow 0 \quad \text{cuando } n \rightarrow \infty.$$

Definimos el clasificador f_n como la función:

$$f_n := \arg \min_{f \in \mathcal{F}} \mathcal{R}_{\text{emp}}(f).$$

Esta es la función del espacio que minimiza el riesgo empírico para la muestra de tamaño n . El proceso de encontrar esta función se conoce como **minimización del riesgo empírico** y es, como veremos a continuación, consistente con el espacio fundional $\mathcal{F}$ si se verifica la ley uniforme de los grandes números para este espacio.

Consideremos:

$$|R(f_n) - R(f_{\mathcal{F}})| = R(f_n) - R(f_{\mathcal{F}}).$$

Puesto que $R(f_n) - R(f_{\mathcal{F}}) \geq 0$, por definición de $f_{\mathcal{F}}$. Sumando y restando cantidades idénticas, esta expresión se puede reescribir como:

$$\begin{aligned} R(f_n) - \mathcal{R}_{\text{emp}}(f_n) + \mathcal{R}_{\text{emp}}(f_n) - \mathcal{R}_{\text{emp}}(f_{\mathcal{F}}) + \mathcal{R}_{\text{emp}}(f_{\mathcal{F}}) - R(f_{\mathcal{F}}) \\ \leq R(f_n) - \mathcal{R}_{\text{emp}}(f_n) + \mathcal{R}_{\text{emp}}(f_{\mathcal{F}}) - R(f_{\mathcal{F}}) \\ \leq 2 \sup_{f \in \mathcal{F}} |\mathcal{R}(f) - \mathcal{R}_{\text{emp}}(f)|. \end{aligned}$$

Dado que $\mathcal{R}_{\text{emp}}(f_n) - \mathcal{R}_{\text{emp}}(f_{\mathcal{F}}) \leq 0$ por definición de f_n , y luego acotando al tomar el supremo de todas las funciones en el espacio $\mathcal{F}$.

De esto podemos concluir:

$$P(|R(f_n) - R(f_{\mathcal{F}})| \geq \varepsilon) \leq P\left(\sup_{f \in \mathcal{F}} |\mathcal{R}(f) - \mathcal{R}_{\text{emp}}(f)| \geq \varepsilon/2\right).$$

Bajo la ley uniforme de los grandes números, el lado derecho tiende a 0, lo que lleva a la consistencia de la minimización del riesgo empírico con respecto a la clase de funciones subyacente $\mathcal{F}$.

En otras palabras,

La convergencia uniforme sobre $\mathcal{F}$ es una condición suficiente para la consistencia de la minimización del riesgo empírico sobre $\mathcal{F}$.

Parte de la elegancia de la teoría VC radica en que el recíproco también es cierto.

Vapnik y Chervonenkis, 1971

La convergencia uniforme

$$P\left(\sup_{f \in \mathcal{F}} |\mathcal{R}(f) - \mathcal{R}_{\text{emp}}(f)| > \varepsilon\right) \rightarrow 0 \quad \text{cuando } n \rightarrow \infty,$$

para todo $\varepsilon > 0$, es una condición necesaria y suficiente para la consistencia de la minimización del riesgo empírico con respecto a $\mathcal{F}$.

El infinito queda muy lejos

¿Qué podemos decir sobre lo que ocurre después de observar solo un número finito de puntos de datos? Detengámonos en la probabilidad del Teorema anterior:

$$P \left(\sup_{f \in \mathcal{F}} |\mathcal{R}(f) - \mathcal{R}_{\text{emp}}(f)| > \varepsilon \right).$$

Consideremos entonces un espacio de funciones finito. Sea $\mathcal{F}_m = \{f_1, f_2, \dots, f_m\}$ un conjunto de m funciones. Cada una de las funciones $f_i \in \mathcal{F}_m$ satisface la ley estándar de los grandes números en la forma de la cota de Chernoff:

$$P(|R(f_i) - \mathcal{R}_{\text{emp}}(f_i)| \geq \varepsilon) \leq 2 \exp(-2n\varepsilon^2).$$

Ahora queremos transformar estas afirmaciones sobre funciones individuales f_i en una ley uniforme de los grandes números. Dada la subatividad de la probabilidad, tenemos:

$$P\left(\sup_{f \in \mathcal{F}} |\mathcal{R}(f) - \mathcal{R}_{\text{emp}}(f)| \geq \varepsilon\right) \leq \sum_{i=1}^m P(|R(f_i) - \mathcal{R}_{\text{emp}}(f_i)| \geq \varepsilon).$$

Y aplicando la cota de Chernoff a cada término en la suma, obtenemos:

$$P\left(\sup_{f \in \mathcal{F}} |\mathcal{R}(f) - \mathcal{R}_{\text{emp}}(f)| \geq \varepsilon\right) \leq m (2 \exp(-2n\varepsilon^2)).$$

Como m es constante

$$2m \exp(-2n\varepsilon^2) \xrightarrow{n \rightarrow \infty} 0$$

Por lo tanto, la minimización del riesgo empírico sobre un conjunto finito de funciones es consistente con respecto a $\mathcal{F}_m$.

En la práctica, nuestros espacios de funciones serán infinitos.
Veremos que podemos reemplazar a m por un valor que depende de cada tipo de espacio funcional y que, de ser finito, será necesariamente polinómico, lo que nos permitirá obtener cotas de generalización. Llamaremos a dicha cantidad, la *dimensión VC*.



Vladimir Vapnik



Alexey Chervonenkis

Como no podemos calcular directamente $\mathcal{R}$, desearíamos acotar la ecuación

$$\sup_{f \in \mathcal{F}} |\mathcal{R}(f) - \mathcal{R}_{\text{emp}}(f)|$$

por una cantidad que dependa de valores empíricos en su totalidad.

Supongamos que tenemos una muestra $(X_i, Y_i)_{i=1, \dots, n}$.

Ahora introducimos una nueva muestra $(X'_i, Y'_i)_{i=1, \dots, n}$, que también se extrae de manera *iid* de la misma distribución subyacente y que es independiente de la primera.

No necesitamos generar esta muestra en la práctica; es solo una herramienta matemática para realizar el análisis.

Definimos el riesgo empírico con respecto a esta muestra como $\mathcal{R}'_{\text{emp}}(f)$. Con la ayuda de esta muestra fantasma, podemos demostrar el siguiente resultado.

Lema de Simetrización

Sea $\mathcal{F}$ el espacio de funciones definido por un algoritmo de aprendizaje. Sean $(X_i, Y_i)_{i=1, \dots, m}$, $(X'_i, Y'_i)_{i=1, \dots, m}$ muestras aleatorias iid. Dada $f \in \mathcal{F}$, sean $\mathcal{R}(f)$ su riesgo, $\mathcal{R}_{\text{emp}}(f)$ su riesgo empírico sobre la primera muestra y $\mathcal{R}'_{\text{emp}}(f)$ el riesgo sobre la segunda. Entonces, para cualquier $\varepsilon > 0$ tal que $m \geq \frac{2}{\varepsilon^2}$, se cumple que


$$P \left(\sup_{f \in \mathcal{F}} |\mathcal{R}(f) - \mathcal{R}_{\text{emp}}(f)| > \varepsilon \right) \leq 2P \left(\sup_{f \in \mathcal{F}} |\mathcal{R}_{\text{emp}}(f) - \mathcal{R}'_{\text{emp}}(f)| > \frac{\varepsilon}{2} \right).$$

Este lema nos permite trabajar con eventos que dependen únicamente de las muestras observadas: Pudimos acotar el riesgo por el riesgo empírico.

Fragmentación

Notemos que, incluso si $\mathcal{F}$ contiene un número infinito de funciones, las diferentes formas en que estas pueden clasificar un conjunto de entrenamiento de n puntos de muestra es finita.

En efecto, para cualquier punto de entrenamiento dado en la muestra, una función puede tomar solo los valores -1 o $+1$.



Dos funciones que separan de igual manera a un par de puntos.

Definición

Sean $\mathcal{F}$ una clase de funciones y sea Z_n un conjunto de n puntos etiquetados, donde

$$Z_n := \{(X_1, Y_1), \dots, (X_n, Y_n)\}.$$

Definimos la relación $\sim$ sobre $\mathcal{F}$:

$$f_1 \sim f_2 \quad \text{si} \quad f_1(X_i) = f_2(X_i) \quad \forall i = 1, \dots, n.$$

Observación

La relación $\sim$ es una relación de equivalencia sobre $\mathcal{F}$. Luego, para una muestra fija, define una partición sobre $\mathcal{F}$.

En una muestra de n puntos $\{X_1, \dots, X_n\}$, una función puede actuar de, como máximo, 2^n formas diferentes.

Así, las únicas funciones que necesitamos considerar para calcular el supremo son las 2^n funciones que podemos obtener en la muestra original y la muestra fantasma juntas. Por lo tanto, podemos reemplazar el supremo sobre $f \in \mathcal{F}$ por el supremo sobre una clase finita de funciones con como máximo 2^n funciones

Definición

Definimos el **conjunto de fragmentación** $\mathcal{F}_{Z_n}$ a cualquier conjunto de representantes de $\mathcal{F}$ bajo la relación de equivalencia $\sim$ para la muestra Z_n .

Definición

Dado un espacio muestral X y una muestra de tamaño n , denotada por

$$Z_n := \{(X_1, Y_1), \dots, (X_n, Y_n)\},$$

definimos el **coeficiente de fragmentación** del espacio funcional $\mathcal{F}$ como:

$$\mathcal{N}(\mathcal{F}, n) = \max_{Z_n} \{|\mathcal{F}_{Z_n}|\} = \max_{\{X_1, \dots, X_n\}} \{|\mathcal{F}_{\{X_1, \dots, X_n\}}| \mid X_1, \dots, X_n \in X\}.$$


$\mathcal{N}(\mathcal{F}, n)$ es el número de formas en las que $\mathcal{F}$ puede separar en dos clases al espacio de entrada X . En el caso de clasificación binaria, como el que estamos tratando, el mayor cardinal posible para un conjunto de fragmentación coincide con el cardinal del conjunto de partes de un conjunto de tamaño n (basta considerar cada subconjunto posible del mismo como aquel donde el clasificador etiqueta con $+1$ todos los valores en el subconjunto y con -1 los valores fuera de él). Entonces, si $\mathcal{N}(\mathcal{F}, n) = 2^n$, existe al menos una muestra de tamaño n que puede ser separada de todas las formas posibles por funciones en $\mathcal{F}$. En este caso, decimos que la clase de funciones $\mathcal{F}$ *fragmenta* al conjunto de n puntos.

En la definición, tomamos el máximo puesto que ciertas muestras pueden no ser fragmentables de la misma manera que otras por $\mathcal{F}$. Consideremos el espacio $\mathbb{R}^2$ y sea $\mathcal{F} = \{f : f(x) = \alpha x + \beta; \alpha, \beta \in \mathbb{R}\}$, el espacio de funciones lineales.


Es claro que podemos separar dos puntos de la manera que deseemos en este espacio, pero no podemos hacer lo mismo con tres puntos *cualesquiera*. En efecto, sea $Z_3 = \{X_1, X_2, X_3\} \in \mathbb{R}^2$ y supongamos que los puntos en dicho conjuntos son colineales. Tomemos el caso en el que el primero y el tercero de ellos pertenecen a la misma categoría, mientras que el que queda en medio a la otra categoría, como en la figura 1 (a).



(a)



(b)



(c)

Figura: Fragmentación de muestras en $\mathbb{R}^2$ de tres y cuatro puntos.

Tomemos $\mathcal{F}_{all}$, el espacio de todos los clasificadores posibles. Es claro que, en este caso, $\mathcal{N}(\mathcal{F}_{all}, n) = 2^{2n}$, pues cualquier muestra de $2n$ puntos puede ser separada de 2^{2n} formas posibles. Entonces, la cota de convergencia uniforme para este espacio es:

$$\begin{aligned} P\left(\sup_{f \in \mathcal{F}_{all}} |R(f) - R_{\text{emp}}(f)| > \varepsilon\right) &\leq 2 \cdot 2^{2n} \exp\left(-\frac{n\varepsilon^2}{4}\right) \\ &= 2 \exp\left(n\left(2\log(2) - \frac{n\varepsilon^2}{4}\right)\right). \end{aligned}$$

Que es una expresión que no tiende a 0 cuando n tiende a infinito. Con lo que sabemos hasta ahora, esto no significa que podamos concluir que la minimización del riesgo empírico usando el espacio de todas las funciones clasificadoras posibles sea inconsistente, dado que la cota de convergencia uniforme anterior es solo una condición suficiente. Pero si podemos dar el siguiente resultado para definir una condición necesaria y suficiente para la consistencia de la minimización del riesgo empírico.

Teorema

La minimización del riesgo empírico es consistente con respecto a un espacio de funciones $\mathcal{F}$ si y solo si

$$\frac{\log(\mathcal{N}(\mathcal{F}, n))}{n} \rightarrow 0 \quad \text{cuando } n \rightarrow \infty.$$

Corolario 1

Si $\mathcal{N}(\mathcal{F}, n)$ es polinómica, entonces la minimización del riesgo empírico es consistente con respecto a $\mathcal{F}$.

Corolario 2

Si $\mathcal{N}(\mathcal{F}, n) = 2^n$, entonces la minimización del riesgo empírico no es consistente con respecto a $\mathcal{F}$. En particular, no es consistente con respecto al espacio de todas los clasificadores posibles $\mathcal{F}_{all}$.

La dimensión VC de una clase de funciones $\mathcal{F}$ es el tamaño máximo de una muestra que puede ser fragmentada por $\mathcal{F}$, es decir:

$$VC(\mathcal{F}) = \max\{n \in \mathbb{N} \mid \mathcal{N}(\mathcal{F}, n) = 2^n\}.$$

Si no existe tal máximo, definimos $VC(\mathcal{F}) = \infty$.

Sea $\mathcal{F}$ una clase de funciones con dimensión VC finita. Entonces

$$\mathcal{N}(\mathcal{F}, n) \leq \sum_{i=0}^{\text{VC}(\mathcal{F})} \binom{n}{i}, \quad \forall n \in \mathbb{N}.$$

En particular, para $n \geq \text{VC}(\mathcal{F})$ se tiene que

$$\mathcal{N}(\mathcal{F}, n) \leq \left(\frac{e \cdot n}{\text{VC}(\mathcal{F})} \right)^{\text{VC}(\mathcal{F})}.$$

La importancia de esta afirmación radica en el último hecho. Si $n \geq VC(\mathcal{F})$, el coeficiente de fragmentación se comporta como una función polinómica del tamaño de la muestra n . Este es un resultado muy notable: una vez que sabemos que la dimensión VC de una clase de funciones $\mathcal{F}$ es finita, ya sabemos que los coeficientes de fragmentación crecen polinómicamente con n . Por los resultados de la sección anterior, esto implica la consistencia de la minimización del riesgo empírico. Nótese que también tenemos una afirmación en la otra dirección. Si la dimensión VC es infinita, esto significa que para cada n existe alguna muestra que puede ser fragmentada por $\mathcal{F}$, es decir, tal que $\mathcal{N}(\mathcal{F}, n) = 2^n$. Para este caso, ya vimos anteriormente que ERM no es consistente. Enunciamos todo esto en el siguiente Teorema.

Teorema

La minimización del riesgo empírico es consistente con respecto a una clase de funciones $\mathcal{F}$ si y solo si $VC(\mathcal{F}) < \infty$.

Una propiedad importante a notar tanto sobre el coeficiente de fragmentación como sobre la dimensión VC es que no dependen de la distribución subyacente P , sino únicamente de la clase de funciones $\mathcal{F}$. Por un lado, esto es una ventaja, ya que todas las cotas de generalización derivadas de estos conceptos se aplican a todas las distribuciones de probabilidad posibles. Por otro lado, esto también puede considerarse una desventaja, ya que los conceptos de capacidad no tienen en cuenta propiedades particulares de la distribución en cuestión. En este sentido, estos conceptos de capacidad a menudo conducen a cotas bastante amplias, pero es lo que desde un comienzo nos interesaba.

Riesgo Empírico (lo que *sí* podemos calcular):

$$\mathcal{R}_{\text{emp}}(f) := \frac{1}{n} \sum_{i=1}^n \ell(X_i, Y_i, f(X_i))$$

Principio ERM (Minimización del Riesgo Empírico):

$$f_n := \arg \min_{f \in \mathcal{F}} \mathcal{R}_{\text{emp}}(f)$$

La motivación proviene de la **Ley de los Grandes Números**:

$$\frac{1}{n} \sum_{i=1}^n \xi_i \xrightarrow{n \rightarrow \infty} \mathbb{E}[\xi] \quad (\xi_i \text{ i.i.d.})$$

La promesa

Para f **fija**, la LGN garantiza:

$$\mathcal{R}_{\text{emp}}(f) \xrightarrow{n \rightarrow \infty} \mathcal{R}(f)$$

Más datos $\Rightarrow$ mejor estimación.

La trampa oculta

Nuestra f_n **depende de los datos**.


La LGN aplica a funciones *fijas*, no a funciones que cambian con la muestra.

El Colapso de la Memorización: $\mathcal{F}_{\text{all}}$

El clasificador “tramposo” (búsqueda irrestricta en $\mathcal{F}_{\text{all}}$):

$$f_n(X) := \begin{cases} Y_i & \text{si } X = X_i \text{ para algún } i \\ +1 & \text{en otro caso} \end{cases}$$

- $\mathcal{R}_{\text{emp}}(f_n) = 0$ (perfecto en train)
- $\mathcal{R}(f_n) = \frac{1}{2}$ (moneda al aire en test)



f_n memoriza el train; ignora el test.

Diagnóstico

Sobreajuste catastrófico.


El algoritmo aprendió los datos, no la regla.

El Dilema de la Complejidad

Descomposición del exceso de riesgo:

$$\underbrace{\mathcal{R}(f_n) - \mathcal{R}(f_{\text{Bayes}})}_{\text{lo que queremos reducir}}$$
$$= \underbrace{\mathcal{R}(f_n) - \mathcal{R}(f_{\mathcal{F}})}_{\text{error de estimación}} + \underbrace{\mathcal{R}(f_{\mathcal{F}}) - \mathcal{R}(f_{\text{Bayes}})}_{\text{error de aproximación}}$$

- **Aprox.:** $\mathcal{F}$ pequeño $\Rightarrow$ alto **sesgo** (subajuste).
- **Estim.:** $\mathcal{F}$ grande $\Rightarrow$ alta **varianza** (sobreajuste).



Inspirado en Figura 2.3 de la tesina.

La Necesidad de un Sesgo Inductivo

Conclusión del bloque


Para que ERM sea **consistente**, el espacio $\mathcal{F}$ debe ser **suficientemente restringido**.

- $\mathcal{F} = \mathcal{F}_{\text{all}} \Rightarrow$ inconsistencia garantizada.
- $\mathcal{F}$ pequeño (e.g., funciones lineales) $\Rightarrow$ bajo error de estimación.
- Todo aprendizaje exitoso impone un **s sesgo inductivo**.

No existe conocimiento sin suposición.
La pregunta es cuál suposición elegir.

Pregunta puente

¿Cómo **medir formalmente** si un espacio $\mathcal{F}$ es lo suficientemente “restringido” para que ERM no nos mienta?



Restringir $\Leftrightarrow$ controlar la capacidad

La Ley que nos Quedó Chica: Convergencia Uniforme

LGN para f fija (lo que ya teníamos):

$$\mathcal{R}_{\text{emp}}(f) \xrightarrow{n \rightarrow \infty} \mathcal{R}(f) \quad \checkmark$$

Lo que realmente necesitamos:

$$\sup_{f \in \mathcal{F}} |\mathcal{R}(f) - \mathcal{R}_{\text{emp}}(f)| \xrightarrow{n \rightarrow \infty} 0 \quad (?)$$

Convergencia *simultánea* para **todas** las $f \in \mathcal{F}$.

¿Por qué la LGN no alcanza?

$f_n = \arg \min_{f \in \mathcal{F}} \mathcal{R}_{\text{emp}}(f)$ **depende de los datos.**

La LGN aplica a funciones *fijas*, no a funciones que cambian con la muestra.

Lo que hay que probar

$$P\left(\sup_{f \in \mathcal{F}} |\mathcal{R}(f) - \mathcal{R}_{\text{emp}}(f)| > \varepsilon\right) \xrightarrow{n \rightarrow \infty} 0$$

para todo $\varepsilon > 0$.


Coeficiente de fragmentación

$$N(\mathcal{F}, n) := \max_{x_1, \dots, x_n \in \mathcal{X}} |\{(f(x_1), \dots, f(x_n)) : f \in \mathcal{F}\}|$$

- Reduce $\mathcal{F}$ (infinito) a un conteo **combinatorio finito**.
- $N(\mathcal{F}, n) \leq 2^n$ siempre; la igualdad = *fragmentación completa*.
- Clasificadores lineales en $\mathbb{R}^2$:

$$N(\mathcal{F}, 3) = 8 = 2^3 \quad \checkmark$$

4 de 8 dicotomías posibles con clasificadores lineales:



$N(\mathcal{F}, 3) = 2^3 = 8$: fragmentación completa.


Dimensión VC

$$VC(\mathcal{F}) := \max\{n \in \mathbb{N} \mid N(\mathcal{F}, n) = 2^n\}$$

El tamaño máximo de una muestra que $\mathcal{F}$ puede fragmentar *completamente*.

- Condensa la complejidad de $\mathcal{F}$ en un **número entero**.
- **Clasificadores lineales en $\mathbb{R}^2$:** $VC(\mathcal{F}) = 3$.
- $VC(\mathcal{F}) = \infty \Rightarrow$ sobreajuste garantizado ($\mathcal{F}_{\text{all}}$).

4 puntos en configuración XOR: ningún clasificador lineal los fragmenta



configuración XOR

$$N(\mathcal{F}, 4) < 16 = 2^4 \Rightarrow VC(\text{lin. en } \mathbb{R}^2) = 3$$

El Truco Analítico: Lema de Simetrización

El obstáculo: la cota original depende de P :

$$P\left(\sup_{f \in \mathcal{F}} |\mathcal{R}(f) - \mathcal{R}_{\text{emp}}(f)| > \varepsilon\right)$$


$\mathcal{R}(f) = \mathbb{E}_P[\dots]$: incalculable.

La idea: introducir una **muestra fantasma** S' :

$$|\mathcal{R}(f) - \mathcal{R}_{\text{emp}}(f)| \lesssim |\mathcal{R}_{\text{emp}}(f) - \mathcal{R}'_{\text{emp}}(f)|$$

El resultado clave

$$P\left(\sup_f |\mathcal{R} - \mathcal{R}_{\text{emp}}| > \varepsilon\right) \leq 2 P\left(\sup_f |\mathcal{R}_{\text{emp}} - \mathcal{R}'_{\text{emp}}| > \frac{\varepsilon}{2}\right)$$



La magia

Pasamos de comparar contra P (desconocida) a comparar **dos muestras finitas**: problema **combinatorio**, no probabilístico.

ERM es universalmente consistente

$$\iff VC(\mathcal{F}) < \infty$$

Hoja de ruta de la prueba

- 1 **Simetrización:** P desconocida $\rightarrow$ muestra fantasma S' .
- 2 **Permutaciones:** problema combinatorio sobre $2n$ puntos.
- 3 **Sauer–Shelah:** $N(\mathcal{F}, 2n) \leq \left(\frac{2n}{VC(\mathcal{F})}\right)^{VC(\mathcal{F})}$.
- 4 **Unión de eventos:** la cota total $\rightarrow 0$ si $VC < \infty$.

Interpretación

Aprender es, fundamentalmente, un problema de **capacidad finita.**

- De intuición estadística (“no sobreajustar”) a **garantía matemática estricta**.
- $VC(\mathcal{F})$ cuantifica la riqueza estructural del modelo.


¿Existe un Algoritmo Maestro?

Hemos demostrado:

- ERM consistente $\iff VC(\mathcal{F}) < \infty$.
- Con $\mathcal{F}$ adecuado, el error es acotable.
- El ideal teórico es f_{Bayes} .

Pregunta natural:

¿Existe f^* que, **en promedio sobre todas las distribuciones** $P(X, Y)$, supere a cualquier otro clasificador?




“Los Teoremas de la Chancha y los Veinte”

Teorema 4.3.1 (Devroye, 1982)

Sea $\varepsilon > 0$. Para cualquier $n \in \mathbb{N}$ y cualquier regla f_n , **existe** una distribución $P(X, Y)$ con $\mathcal{R}(f_{\text{Bayes}}) = 0$ tal que:

$$\mathbb{E}[\ell(X, Y, f_n)] \geq \frac{1}{2} - \varepsilon$$

- Por cada universo donde f_n triunfa, existe un universo “espejo” donde falla como una moneda.
- Promediado sobre **todas** las P : **todo algoritmo rinde igual**.
- No contradice consistencia: la distribución adversarial depende de n .



Área bajo ambas curvas es igual. Inspirado en Figura 4.2 de la tesina.

El Sesgo Inductivo: La Moraleja del Machine Learning


La lección central

Aprender “en el vacío” es **imposible**.
Para aprender, debemos **asumir**.

Sesgo inductivo

Restricción sobre el espacio de distribuciones o funciones que el algoritmo considera plausibles.

- **k-NN**: puntos cercanos tienen etiquetas similares.
- **SVM**: las clases son separables por un margen.
- **Red neuronal**: la función es aproximable por composición de no-linealidades.



La clave del éxito práctico

No existe el algoritmo perfecto: el éxito es elegir aquel cuyas **suposiciones** coincidan con la **física del problema**.

La Paradoja Moderna: ¿Qué Dice la Teoría?

El marco clásico predice

Si $VC(\mathcal{F}) = d < \infty$, con alta probabilidad:

$$\mathcal{R}(f_n) \leq \hat{\mathcal{R}}_n(f_n) + O\left(\sqrt{\frac{d + \ln(1/\delta)}{n}}\right)$$


- **Capacidad alta** $\Rightarrow$ cota grande.
- **Sobreparametrización** $\Rightarrow$ sobreajuste inevitable.

Lo que observamos en la práctica

GPT-4: $\sim 1,8 \text{ T}$ parámetros, $n \ll$ parámetros.

Las cotas VC serían **astronómicamente grandes**...

...y sin embargo, generalizan.



Fenómeno de “doble descenso”: el error *vuelve a bajar* tras la sobreparametrización.

Leyes de Escalamiento: Fuerza Bruta → Necesidad Teórica


Empirismo a escala (Kaplan et al., 2020)

$$L(N) \approx \left(\frac{N_c}{N}\right)^\alpha, \quad \alpha \approx 0,076$$

La pérdida sigue una **ley de potencias** en parámetros N , tokens y cómputo.

Transformers, LLMs, modelos de difusión.

- **Hoy:** escalamos porque funciona empíricamente.
- **Mañana:** los límites físicos y económicos frenarán el escalado.
- **La teoría es el cuello de botella:** sin fundamentos de generalización para regímenes sobrep parametrizados, avanzamos a ciegas.



Ley de potencias empírica (Kaplan et al., 2020). Los valores son ilustrativos.

Fuerza

límites

Necesidad

**“Dios mueve al jugador, y éste, la pieza.
¿Qué Dios detrás de Dios la trama empieza?”**

Jorge Luis Borges, *Ajedrez*, 1960

Detrás de cada algoritmo, una pregunta matemática.

La tesina fue un paso; el camino sigue abierto.

Muchas gracias.

¿Preguntas?